

미디어 채널은 리셀 시장 가격을 선행하는가?

자산 유형별 Granger 인과성 분석과 머신러닝 검증

이승현

윤재은

최형호

요약

스니커즈, 트레이딩 카드, 빌딩 블록(레고)으로 대표되는 리셀(resell) 시장은 지난 5년간 글로벌 단위로 빠르게 성장하였으나, 가격 형성에 영향을 미치는 정보 채널에 대한 실증 연구는 제한적이다. 본 연구는 다섯 가지 미디어 채널 — 검색 트렌드(Google Trends), 뉴스 보도량(GDELT volume), 뉴스 감성(GDELT tone), YouTube 조회수, YouTube 댓글 감성(FinBERT)—이 리셀 자산 가격을 선행하는지, 그리고 선행 채널 구성이 자산 유형마다 다른지를 검증한다.

세 자산군(스니커즈·카드·레고)에서 각 5개 아이템, 총 15개 아이템에 대해 2022년 1월부터 2025년 12월까지 48개월 월별 패널을 구축하였다. 자산별로 다섯 채널 각각에 대해 단독(bivariate) Granger 인과성 검정을 수행하여 3 자산 $\times$ 5 채널 = 15회의 유의성을 평가하였다. 자산별 유의 채널 집합 간 Jaccard 유사도를 통해 채널 구성의 이질성을 정량화하였으며, 연속된 후속 단계로 XGBoost와 Diebold-Mariano 검정을 활용하여 선별 채널 모형의 예측 성능을 평가한다.

실증 분석 결과, 15회 Granger 검정 중 4회가 유의($p < 0.05$), 1회가 경계 수준($0.05 \leq p < 0.10$)으로 관찰되었다. 스니커즈에서는 Google Trends(CH1), 뉴스 감성(CH3), YouTube 조회수(CH4)가, 카드에서는 Google Trends(CH1)가 가격을 선행하는 잠정적 증거가 확인되었다(RQ1). 자산쌍 간 Jaccard 유사도는 sneakers-cards = 0.333, 그 외 = 0.000으로, 자산 유형 간 유의 채널 구성이 대체로 상이하되 검색 트렌드(CH1)에서 부분적 중복이 존재한다(RQ2). 자산-평균 검정과 RQ3 머신러닝 단계의 분석 단위 불일치를 보완하기 위해 5개 아이템을 횡

단면으로 두는 Dumitrescu and Hurlin [2012] 패널 Granger 검정을 보충 수행하였으며, BH 보정 후에도 자산-평균과 DH 양쪽에서 일관되게 유의한 채널은 cards-CH1 한 조합으로 집약된다. 보충적으로 BH 보정 후 유의가 유지된 두 조합에 대한 직교화 충격반응함수는 1~2개월 선행 + 4개월 내 감쇄의 공통 패턴을 보이되 부호가 정반대로 나타나, cards-CH1은 양(+10.80, 1개월), sneakers-CH3는 음(-2.82, 1개월)의 가격 반응이 95% 잔차 부트스트랩 신뢰구간에서 0을 포함하지 않았다. XGBoost 예측 비교에서는 15개 아이템 중 11개(73%)에서 Granger 선별 모형(Model B)과 전채널 모형(Model A) 간 DM 검정상 통계적으로 유의한 차이가 없었으나, 자산별 평균 RMSE는 sneakers·lego에서 Model A가 일관되게 낮고 2개 아이템(jordan1, falcon)에서는 Model A가 유의하게 우수하였다. 또한 절제 실험에서 Granger 유의 채널을 제거해도 일부 자산의 AUC가 하락하지 않아, Granger 유의성이 곧바로 표본 외(out-of-sample) 예측 유용성을 보장하지 않음을 보였다(RQ3). 따라서 Granger 선별은 “우수한 예측 변수 선택법”이라기보다 “큰 손실 없이 채널 수를 줄일 수 있는 탐색적 축소 도구”로 해석하는 것이 적절하다. SHAP 분석에서도 채널 변수의 절대 기여도는 가격 모델 변수보다 현저히 작았으며, Granger 순위와 SHAP 순위 간 불일치가 관찰되었다. 이는 통계적 선행성과 비선형 예측 기여도가 서로 다른 측정 대상임을 보여 주며 §5.2에서 다룬다. 표본 크기($N = 48$)와 다중 검정 구조를 고려할 때, 본 연구의 결과는 탐색적 발견으로 해석되어야 한다.

핵심어: 리셀 시장, Granger 인과성, 미디어 선행 지표, GDELT, Google Trends, FinBERT, XG-

요약

[english] The resell market for sneakers, trading cards, and LEGO sets has grown rapidly on a global scale over the past five years, yet empirical research on the information channels that shape price formation remains limited. This study examines whether five media channels—Google Trends search interest, GDELT news volume, GDELT news sentiment, YouTube view counts, and YouTube comment sentiment (FinBERT)—*lead* resell asset prices, and whether the composition of significant leading channels differs across asset types.

We construct a 48-month monthly panel from January 2022 to December 2025 covering 15 items (5 per asset class: sneakers, trading cards, and LEGO sets). Bivariate Granger causality tests are conducted for each asset-type $\times$ channel pair (3 assets $\times$ 5 channels = 15 tests). Jaccard similarity between asset-specific sets of significant channels quantifies compositional heterogeneity (RQ2), and XGBoost with Diebold–Mariano tests evaluates the predictive performance of Granger-selected channel models versus full-channel models (RQ3).

Out of 15 Granger tests, 4 are significant ($p < 0.05$) and 1 is marginal ($0.05 \leq p < 0.10$). Tentative evidence of price leadership is found for Google Trends, news sentiment, and YouTube views in sneakers, and for Google Trends in trading cards (RQ1). Jaccard similarity is 0.333 for the sneakers–cards pair and 0.000 otherwise, indicating largely heterogeneous channel compositions across asset types (RQ2). To reconcile the analytical-unit gap between asset-level Granger tests and the item-level XGBoost stage, we additionally apply the panel Granger non-causality test of Dumitrescu and Hurlin [2012] treating the five items within each asset as cross-sections; af-

ter BH correction, only *cards–CH1* remains significant in both the asset-mean Granger and the panel DH test, while the strongest asset-mean finding (sneakers–CH3) is reduced to non-significance under DH, suggesting possible aggregation-induced amplification. A complementary six-variable VAR with block and individual Granger tests (controlling for cross-channel multicollinearity) confirms that the only finding surviving BH correction across all three tests is *cards–CH1*, which we report as the most robust asset-common leading channel. Supplementary orthogonalised impulse-response functions for the two BH-robust channels show a common short-lead pattern (peak at 1–2 months, decay within 4 months) but opposite signs: *cards–CH1* produces a positive price response (+10.80 at horizon 1) while *sneakers–CH3* produces a negative one (−2.82 at horizon 1), with 95% residual-bootstrap CIs excluding zero in both cases. In XGBoost comparisons, 11 of 15 items (73%) show no statistically significant difference between Granger-selected (Model B) and full-channel (Model A) models by DM test; however, asset-level mean RMSE consistently favors Model A for sneakers and LEGO, and two items significantly favor Model A. Additional ablation tests show that removing Granger-significant channels does not necessarily reduce AUC, indicating that Granger significance does not directly translate into out-of-sample predictive usefulness (RQ3). We therefore interpret Granger selection as an exploratory channel-reduction device rather than a superior feature-selection rule. Given the sample size ($N = 48$) and multiple testing structure, all findings should be regarded as *exploratory*.

Keywords: Resell market, Granger causality, Media leading indicators, GDELT, Google Trends, FinBERT, XGBoost, SHAP

1 서론

스니커즈 리셀 플랫폼 *StockX*, 트레이딩 카드 그 레이딩 시장 (PSA 10), 그리고 단종 (retired) 레 고 세트 등은 한정된 공급, 표준화된 품질 보증, 그리고 디지털 거래 인프라의 결합을 통해 대안 자산 (*alternative asset*)의 한 축으로 자리잡았다. 거래량과 가격 변동성은 주식·암호화폐 시장에 비해 작지만, 가격 결정 구조 자체는 정보 비대칭과 관심 (*attention*)—즉 잠재 구매자·수 집가의 인지 노출량—에 민감하다는 점에서 금융 시장과 본질을 공유한다.

기존 금융 연구는 검색 트렌드와 거래량의 관계 [Da et al., 2011, Preis et al., 2013], 뉴스 텍스트의 감성과 수익률의 관계 [Tetlock, 2007, Loughran and McDonald, 2011], 그리고 소셜 미디어 무드와 주가 변동의 관계 [Bollen et al., 2011]를 충분히 축적해 왔다. 그러나 이러한 통찰이 리셀 시장에서도 그대로 작동하는지, 그리고 자산 유형 (스니커즈·카드·레고)에 따라 어떤 채널이 선행적 역할을 하는지는 거의 연구되지 않았다.

본 연구는 다음 세 가지 연구 문제와 대응 가설을 제기한다.

RQ1 다섯 가지 미디어 채널은 각 리셀 자산의 가격을 Granger 의미에서 선행하는가?

H1 다섯 채널 중 적어도 일부는 리셀 자산 가격에 대해 Granger 인과성을 보인다. 즉 단독 Granger 검정에서 귀무가설 $H_0: \gamma_1 = \dots = \gamma_L = 0$ 이 기각되는 (자산, 채널) 조합이 존재한다.

RQ2 유의한 채널 구성이 자산 유형 (스니커즈·카드·레고)마다 다른가?

H2 H1에서 유의로 판정된 채널 집합은 자산 유형 간에 차별화된다. 자산쌍 간 Jaccard 유사도 $J < 0.6$ 이 관찰된다.

RQ3 Granger 검정으로 선별된 채널만으로 학습한 예측 모형 (Model B)은 전 채널을 사용한 모형 (Model A) 대비 표본 외 예측 성능을 큰 손실 없이 유지하는가?

H3 H1의 유의 채널만으로 구성된 Model B의 예측 오차는 Model A 대비 통계적으로 구분되지 않는다. 단, Model B가 유의하게 우수한 경우는 강한 지지로, Model A가 유의하게 우수한 경우는 Granger 선별의 정보 손실로 해석한다.

본 연구의 기여는 세 가지로 요약된다. 첫째, 자산 유형 단위에서 다섯 미디어 채널의 선행성을 단독 Granger 검정으로 비교하는 비교 가능한 설계를 제시한다. 둘째, 가격 시계열 외 모든 비가격 지표는 사전에 점수 변환을 거쳐 동일 단위로 투입함으로써, 이질적 데이터 소스 간 직접 비교의 위험을 줄였다. 셋째, 통계적 인과성 검정과 XGBoost + SHAP 예측 검증을 결합하여, 통계적 선행성 (*causality lead*)과 표본 외 예측 유용성 (*out-of-sample predictive utility*)이 반드시 일치하지 않을 수 있음을 리셀 시장 자료에서 탐색적으로 평가한다.

2 관련 연구

2.1 검색 관심과 자산 가격

검색 엔진 사용량은 잠재 투자자·소비자의 능동적 정보 수요 (*active information demand*)를 직접적으로 측정하는 지표로 자리잡았다. Da et al. [2011]은 미국 종목별 Google 검색 빈도 (SVI)가 산업·시장 수준 이상의 개별 종목 관심을 측정하며, 개인 투자자의 관심 증가는 단기 가격 압력과 장기 가격 반전 패턴 모두와 체계적으로 연관됨을 보였다. Preis et al. [2013]는 거래 행태와 검색량 간의 동적 관계를 정량화하여, 특정 키워드 (예: “debt”) 검색의 급증이 향후 시장 하락을 선행하는 신호로 해석될 수 있음을 실증하였다. Joseph et al. [2011]은 S&P 500 종목에 대해 검색 빈도가 비정상 수익률과 거래량 모두를 예측한다는 결과를 보고하였고, Vlastakis and Markellos [2012]는 검색량으로 근사한 정보 수요가 변동성·거래량과 양의 관계를 가짐을, Vozlyublennaiia [2014]는 검색 기반 관심의 단기 충격이 지수 수익률 패턴을 변화시킴을 보고 하였다. 위키피디아·뉴스 검색 등

인접 디지털 흔적 자료를 활용한 연구도 누적되었는데, Bordino et al. [2012]는 Yahoo Finance 종목 페이지에 대한 검색 쿼리가 거래량을 예측함을 보였으며, Moat et al. [2013]와 Curme et al. [2014]는 위키피디아 페이지 조회 패턴이 주식 시장의 가격 변동을 선행하는 행동학적 신호를 담고 있음을 보고하였다.

이들 연구는 일관되게 검색·조회는 잠재 수요의 선행 지표라는 직관을 지지하며, 본 연구는 동일 직관을 리셀 시장 아이템 단위로 이식한다. 다만 주식 시장 연구가 종목 단위 일별·주별 검토에 주로 집중한 반면, 본 연구는 자산 유형 수준의 월별 검토로 단위를 변경함으로써, 검색이 어떤 자산군에서 가장 강한 선행 신호로 작동하는지를 비교 가능하도록 설계한다.

2.2 뉴스 텍스트와 감성 분석

뉴스의 텍스트적 정보 내용이 자산 가격에 미치는 영향에 관한 실증은 Tetlock [2007]로부터 본격화되었다. 그는 *Wall Street Journal*의 “Abreast of the Market” 칼럼에서 추출한 비관 척도가 다우존스 지수의 단기 수익률을 선행적으로 예측한다는 결과를 보고하였고, Tetlock et al. [2008]은 기업 관련 뉴스의 부정적 단어 빈도가 회계적 펀더멘털(이익, 거래량)에 대한 추가 정보를 담고 있음을 보였다. García [2013]는 1905–2005년 *New York Times*의 경제 칼럼 감성을 분석하여, 경기 침체기일수록 미디어 감성의 수익률 예측력이 강화된다는 상태 의존성을 발견하였다. Engelberg and Parsons [2011]은 동일 사건에 대한 지역별 보도량 차이를 외생적 식별 전략으로 활용하여, 미디어 보도 자체가 거래 행태에 인과적 영향을 미친다는 강한 증거를 제시하였다.

방법론 측면에서 Loughran and McDonald [2011]은 일반 사전(Harvard General Inquirer)이 금융 텍스트에 부적합하다는 점을 지적하며 금융 도메인 사전을 제안하였고, Kearney and Liu [2014]와 Loughran and McDonald [2016]은 금융 텍스트 감성 분석의 방법론적 조류를 종합적으로 정리하였다. 한편 Heston and Sinha [2017]은 뉴스 보도량 대비 감성의 부호가 수익

률 예측에 미치는 한계 기여를 정량화하여, “보도되었다”와 “어떻게 보도되었다”를 분리 평가하는 설계의 중요성을 강조하였다.

본 연구의 CH2(뉴스 보도량)와 CH3(뉴스 감성)는 위 두 차원—보도의 양과 어조—을 GDELT 프로젝트[Leetaru and Schrodtt, 2013]의 *timelinevolnorm*과 *timelinetone*으로 각각 측정한다. GDELT 톤은 도메인 특화 사전이 아닌 일반 감성 점수라는 한계를 지니나, 본 연구의 분석 기간(2022–2025) 동안 4년 단위의 역사 자료를 무료로 일관되게 제공한다는 운용상 장점이 크다(자세한 한계 논의는 §3.3 및 §5.4 참조).

2.3 소셜 미디어·이용자 생성 콘텐츠와 자산 가격

이용자 생성 콘텐츠(user-generated content)는 미디어 콘텐츠의 양과 질 모두를 대중의 시각에서 측정한다는 점에서 전통 뉴스와 구별된다. Antweiler and Frank [2004]는 Yahoo Finance 주식 게시판 메시지의 정보 내용이 변동성과 거래량을 예측함을 보였으나, 평균 수익률에 대한 효과는 약함을 보고하였다. Bollen et al. [2011]은 트위터 무드 지표가 다우존스 지수의 단기 변동을 예측함을 보였으며, Sprenger et al. [2014]는 종목별 트위터 메시지의 감성·메시지 수 모두 비정상 수익률과 거래량을 예측함을 정량적으로 입증하였다. 이들 연구는 공통적으로 이용자 콘텐츠의 양과 질이 시장 관심을 반영한다는 직관을 지지한다.

본 연구의 CH4(YouTube 조회 수)와 CH5(YouTube 댓글 감성)는 동일 직관을 영상 플랫폼으로 확장한다. CH4는 자산-아이템별 “resell, review” 키워드를 기반으로 수집한 영상의 월별 조회수 합산(아이템 내 z-score)으로, 정보 탐색 의도를 측정한다. CH5는 조회수 상위 영상의 영어 댓글에 대해 Araci [2019]의 FinBERT를 적용하여 $P(\text{pos}) - P(\text{neg})$ 의 월 평균으로 산출한다. FinBERT는 Devlin et al. [2019]의 BERT를 금융 도메인 텍스트로 추가 학습한 모형으로, 일반 도메인 감성 분류기 대비 금융 어휘에 대한 분류 정확도가 높다는 점에서

채택하였다.

2.4 머신러닝 기반 예측과 해석

표 형식 시계열의 분류·회귀 과제에서 트리 부스팅 모형은 강건한 성능을 보여 왔으며, 그중 XGBoost[Chen and Guestrin, 2016]는 효율적 구현과 정규화 항을 결합하여 사실상 표준 도구로 자리잡았다. 금융 영역에서도 Gu et al. [2020]은 미국 주식 횡단면 수익률 예측에 다양한 머신러닝 모형(선형, 트리, 신경망)을 비교 적용하여, 트리 계열과 얇은 신경망이 일관되게 선형 회귀 대비 우월한 예측력을 보임을 보고하였다.

머신러닝 모형의 해석 가능성에 관해서는, SHAP[Lundberg and Lee, 2017]이 게임 이론의 Shapley 값을 모형 예측에 적용하여 개별 예측에 대한 변수별 한계 기여도를 통일적으로 분해하는 표준 도구로 자리잡았다. SHAP은 트리 부스팅과 결합 시 정확한 계산이 가능하며, 본 연구는 이를 통해 채널별 평균 |SHAP|를 “전역(global) 변수 중요도”로 사용한다. 본 연구는 Granger 검정에 의한 통계적 선행성과 XGBoost+SHAP에 의한 예측 기여도를 같은 데이터로 직접 대조함으로써, 인과성과 예측력을 분리하여 평가하는 설계상의 차별점을 가진다.

2.5 대안 자산·리셀 시장 연구의 공백

대안 자산 수익률 연구는 다양한 수집품 클래스를 누적해 왔다. Burton and Jacobsen [1999]은 수집품 투자 수익률 측정 방법론을 정리하여 수집품이 양의 실질 수익률을 보이거나 주식 대비 위험이 크다는 점을 보였고, Mei and Moses [2002]는 반복 거래 자료로 1875–2000년 미술 가격 지수를 추정해 미술이 채권을 상회하나 주식 보다는 낮은 수익률을 가짐을 보고하였다. Renneboog and Spaenjers [2013]은 1957–2007년 헤도닉 회귀로 미술 시장의 실질 연 수익률을 약 4%로 추정하면서 소비자 신뢰와 미술 시장 정서가 가격을 예측함을 보였다. Dimson et al. [2015]은 보르도 와인의 실질 연 수익률이 4.1%로 채권·미술·우표를 상회함을 보였다.

본 연구가 다루는 세 자산군에 대해서는, Do-

brynskaya and Kishilova [2022]이 1987–2015년 eBay 거래 자료를 바탕으로 LEGO 세트의 연 평균 명목 수익률을 약 11%(실질 8%)로 추정하여 LEGO가 주식·채권·금·일부 대안 자산을 상회한다는 결과를 보고하였다. 스니커즈 재판매 시장에 대해서는 Raditya et al. [2021]이 StockX 데이터에 선형 회귀와 랜덤 포레스트를 적용해 재판매 가격을 예측하는 등 기계 학습 기반 가격 예측 연구가 진행 중이며, 트레이딩 카드(포켓몬·스포츠 카드 등)에 대한 연구는 학위논문 수준의 사례 분석이 산발적으로 존재한다.

이들 선행 연구는 개별 자산 수익률을 측정하는 데 집중한 반면, 여러 자산군을 동일 기간·동일 채널 정의로 직접 비교하여 미디어 채널의 선행성을 평가한 실증 연구는 저자들이 확인한 범위에서 매우 제한적이다. 본 연구는 이 공백을 메우는 것을 1차 목표로 한다.

3 방법론

3.1 전체 설계

본 연구는 다음 단계로 구성된다.

1. 가격·채널 데이터 수집(STEP 01–04).
2. 채널별 점수 변환 및 결측 처리(STEP 05–06).
3. ADF 정상성 검정 및 필요 시 1차 차분(STEP 07).
4. 자산별 단독 Granger 인과성 검정(STEP 08).
5. Jaccard 유사도를 통한 자산별 유의 채널 구성 비교(STEP 08).
6. XGBoost + SHAP + Diebold–Mariano 검정을 통한 예측 검증(STEP 09).

3.2 데이터

기간 및 단위. 분석 기간은 2022년 1월부터 2025년 12월까지의 48개월이며, 모든 변수는 월(month) 단위로 집계된다. 자산군은 스니커즈

(sneakers), 트레이딩 카드(cards), 레고(lego) 의 셋이며, 각 자산군에 대해 5개 대표 아이템을 선정하여 총 15개 아이템 × 48개월 = 720개 아이템-월 패널을 구축하였다.

아이템 선정 기준. (i) 2022년 이전부터 시장이 형성되어 48개월 연속 가격 관측이 가능할 것, (ii) 자산군 내에서 거래 빈도와 인지도가 충분히 높을 것, (iii) Google Trends에서 검색량이 측정 가능할 것 (0이 다수 발생하는 후보는 제외)을 동시에 만족시키는 아이টে를 자산군별 5개씩 선정하였다(표 1).

가격 자료. 스니커즈는 StockX의 미국 사이즈 10 거래가, 카드는 PriceCharting의 PSA 10 등급 가격, 레고는 BrickRanker의 신품 봉인 가격을 사용하였다. 월별 평균 가격(mean_price)과 거래 건수(tx_count)를 추출하였으며, 거래 건수가 3 미만인 월은 선형 보간으로 대체하였다.¹

한계 및 자료 변경 내역. 본 패널은 다음의 자료원·아이템 변경을 거쳐 확정되었다. (i) 레고는 PriceCharting이 2023년 11월 이후 데이터만 보유하여 BrickRanker로 전환. (ii) 일부 레고 아이টে는 Google Trends 0 빈도가 과다하여 대체 (자세한 변경 이력은 부록 표 19 참조). (iii) sneakers_jordan1은 *Chicago Lost & Found*(2022-11 출시)이 초기 7개월 가격이 부재하여 *Bordeaux*로 변경. (iv) cards_charizard1은 *Evolving Skies* #74의 URL이 다른 카드로 리다이렉트되어 *Shining Fates SV107*로 변경.

3.3 채널 정의 및 점수 변환

다섯 채널의 정의와 변환 규칙은 표 2와 같다. 원시 데이터를 Granger 검정에 직접 투입하지 않으며, 모든 채널은 사전에 다음의 표준 변환을 거쳐 동일 단위로 비교 가능하도록 정렬한다.

CH1 (Google Trends). pytrends를 사용하여 아이টে별 영문 키워드(예: “*Jordan 1 Bordeaux*”)의 월별 평균 검색 관심도를 수집하였다. 지역은 전 세계(geo='')로 설정하였다.

¹연속 3개월 이상 tx_count가 3 미만인 경우는 해당 기간을 제외 검토하였다. 본 연구의 15개 아이টে 중 이 기준에 해당된 사례는 sneakers_yeezy(StockX 거래량 표본 추출 아티팩트로 인한 4개월 결측, 선형 보간으로 처리)이며 한계 절에 명시한다.

CH2·CH3 (GDELT). CH2는 timelineevolnorm 모드를 사용하여 일별 정규화된 보도량을 받고 월평균을 취하며, CH3는 timelinetone 모드의 일별 평균 톤(원범위 -10 ~ +10)을 월평균 취한 뒤 10으로 나누어 -1 ~ +1로 재정규화한다.

CH3 한계. 원래 설계는 NewsAPI로 수집한 도메인 텍스트에 FinBERT를 적용하는 것이었으나, NewsAPI 무료 플랜의 30일 역사 자료 제한으로 4년 길이 수집이 불가능하여 GDELT timelinetone으로 대체하였다. GDELT 톤은 일반 어휘 기반 자동 산출 점수로, 도메인 특화 감성 분석 대비 신호 대 잡음비가 낮을 가능성이 있다(한계 절 명시).

CH4 (YouTube 조회수). search.list와 videos.list 두 엔드포인트를 결합하여 검색을 수행한다. 누적 왜곡을 방지하기 위해 영상의 publishedAt이 해당 월 1일부터 말일 사이인 영상만을 집계하며, 이를 위해 publishedAfter와 publishedBefore 파라미터로 구간을 강제한다. 검색 키워드는 자산-아이টে별로 resell, review, price 등 정보 탐색형 어휘를 결합하여 사전에 고정하였다(예: “*Jordan 1 Bordeaux resell review*”, “*LEGO Millennium Falcon 75192 review sealed price*”; 전체 목록은 scripts/collect_youtube.py 참조). 월별 영상 조회수 합산을 log1p로 변환한 뒤 아이টে 내 z-score를 취하여 score_ch4로 정의한다.²

CH4 의미 한계. 검색 키워드가 resell·review 중심이므로, CH4는 일반 팬덤·hype보다는 정보 탐색 의도(information-seeking intent)를 측정한다. 이 점은 결과 해석에서 명시한다.

CH5 (YouTube 댓글 감성). 조회수 상위 15개 영상 각각에서 관련도(order=relevance) 기준 30개씩 댓글을 수집한 뒤, langdetect로 영어 댓글만 필터링한다. 필터링된 댓글에 대

²스케일 일관성 주. 본 변환으로 산출된 score_ch4는 Granger 검정용 자산 시계열(아이টে 평균)에 그대로 사용된다. XGBoost 단계(§3.8)에서는 모든 채널 점수가 추가로 전역 z-score 정규화를 거치므로, CH4는 이중 정규화(아이টে 내 → 전역)된다. 이는 채널 간 스케일 통일을 위한 의도된 처리이며 모형의 단조 변환 불변성으로 인해 트리 기반 XGBoost 예측에는 실질적 영향이 없으나, SHAP 절대값 해석 시 본 처리를 감안해야 한다.

표 1: 선정된 15개 아이템과 출처. 본 연구의 분석 대상은 스니커즈·트레이딩 카드·레고의 세 자산군이며, 각 자산군에서 (i) 2022년 이전부터 시장이 형성되어 48개월 연속 가격 관측이 가능하고, (ii) 자산군 내 거래 빈도와 인지도가 충분히 높으며, (iii) Google Trends에서 검색량이 측정 가능한 5개 대표 아이템을 선정 하였다. 가격 출처는 자산군별로 다르며, 스니커즈는 *StockX*의 미국 사이즈 10 거래가, 카드는 *PriceCharting*의 PSA 10 등급 가격, 레고는 *BrickRanker*의 신품 봉인(new sealed) 가격을 사용하였다. *sneakers_jordan1*과 *cards_charizard1*은 초기 후보 아이템의 출시일·URL 문제로 교체되었으며, 자세한 변경 이력은 부록 표 19에 정리하였다.

자산군	ID	아이템	출처
sneakers	sneakers_jordan1	Air Jordan 1 Retro High OG Bordeaux	StockX
sneakers	sneakers_panda	Nike Dunk Low Panda	StockX
sneakers	sneakers_yeezy	Yeezy 350 V2 Zebra	StockX
sneakers	sneakers_travis	Travis Scott Jordan 1	StockX
sneakers	sneakers_nb550	New Balance 550 White/Green	StockX
cards	cards_charizard1	Charizard VMAX, Shining Fates SV107	PriceCharting (PSA 10)
cards	cards_charizard2	Charizard GX, Hidden Fates	PriceCharting (PSA 10)
cards	cards_umbreon	Umbreon VMAX Alt Art	PriceCharting (PSA 10)
cards	cards_rayquaza	Rayquaza VMAX Alt Art	PriceCharting (PSA 10)
cards	cards_pikachu	Pikachu VMAX	PriceCharting (PSA 10)
lego	lego_falcon	Millennium Falcon 75192	BrickRanker (new sealed)
lego	lego_hogwarts	Hogwarts Castle 71043	BrickRanker (new sealed)
lego	lego_titanic	Titanic 10294	BrickRanker (new sealed)
lego	lego_porsche	Porsche 911 42096	BrickRanker (new sealed)
lego	lego_bugatti	Bugatti Chiron 42083	BrickRanker (new sealed)

표 2: 다섯 미디어 채널의 정의, 자료원, 점수 변환 규칙, 그리고 최종 범위. 본 연구는 원시 자료를 Granger 검정에 직접 투입하지 않으며, 모든 채널은 사전에 표준 변환을 거쳐 동일 단위로 비교 가능하도록 정렬된다. CH1(Google Trends)은 *pytrends* API로 영문 키워드의 월별 검색 관심도를 수집한 뒤 월평균을 취한다. CH2(뉴스 보도량)와 CH3(뉴스 감성)는 GDELT 프로젝트의 *timelinevolnorm*과 *timelinetone* 모드에서 일별 자료를 받아 월평균으로 집계하며, CH3는 원범위(−10 ~ +10)를 10으로 나누어 −1 ~ +1로 재정규화한다. CH4(YouTube 조회수)는 *publishedAt*이 해당 월에 속하는 영상의 조회수 합산을 $\log_{1p}$ 변환한 뒤 아이템 내 z-score를 취한다(누적 왜곡 방지). CH5(YouTube 댓글 감성)는 조회수 상위 영상의 영어 댓글에 대해 FinBERT로 $P(\text{pos}) - P(\text{neg})$ 를 계산한 뒤 월 평균을 취한다. CH3의 GDELT 대체 사유와 한계는 §3.3에서 상세 논의한다.

ID	이름	자료원	변환 방식	범위
CH1	Google Trends	<i>pytrends</i>	월 평균	0–100
CH2	뉴스 보도량	GDELT <i>timelinevolnorm</i>	일별 → 월 평균	0–1
CH3	뉴스 감성	GDELT <i>timelinetone</i>	월 평균 ÷ 10	−1 ~ +1
CH4	YouTube 조회수	YouTube Data API	일별 조회수 합산 → $\log_{1p}$ → 아이템 내 z-score	z-score
CH5	YouTube 댓글 감성	YouTube + FinBERT	$P(\text{pos}) - P(\text{neg})$ 월 평균	−1 ~ +1

해 ProsusAI/finbert[Araci, 2019]로 $P(\text{pos})$, $P(\text{neg})$, $P(\text{neu})$ 를 산출하고, 월 단위로 $P(\text{pos}) - P(\text{neg})$ 의 평균을 score_ch5로 정의한다.

결측 처리. 단일 또는 2개월 연속 결측은 선형 보간으로 채우며, 3개월 이상 연속 결측은 보간하지 않고 결과 해석 시 한계로 명시한다. GDELT 일부 아이템에서 발생한 결측은 검색 쿼리를 수정하여 재수집하였다 (부록 변경 이력 참조).

3.4 ADF 정상성 검정

Granger 인과 검정은 시계열의 정상성을 전제로 하므로, 본 연구는 가격 및 다섯 채널 점수 각각에 대해 단위근의 부재를 사전 점검한다. 점검 도구는 Dickey and Fuller [1979]의 Augmented Dickey-Fuller 검정이며, 귀무가설 “단위근 존재”가 유의수준 5%에서 기각되지 않는 시계열은 1차 차분된 형태로 변환한 뒤 동일 검정을 재실행한다. 자산-채널 단위로 이 절차를 반복하여 정상성 처리 결과를 results/stationarity.csv에 기록하고, 후속 Granger 검정에서는 차분이 필요한 시계열에 한해 일관되게 차분값을 사용한다.

3.5 Granger 인과성 검정

분석 단위. 자산(asset) 수준의 대표 시계열을 사용한다. 즉, 각 자산군에서 5개 아이템의 월별 가격과 채널 점수를 평균하여 자산-월 단위 시계열을 만들고, 이 시계열에 대해 Granger 검정을 수행한다. 이는 아이템 간 독립 검정에서 발생하는 사례별 잡음을 평균을 통해 감쇄하기 위함이며, 자산 단위 비교(RQ2)와 직접 정렬된다.

검정 형태. 각 (자산, 채널) 쌍을 대상으로 Granger [1969]의 이변량 인과 검정 절차를 적용한다. 구체적으로 가격의 자기회귀만을 포함한 제한 모형과, 여기에 한 채널의 시차값을 추가한 비제한 모형을 각각 추정한 뒤 잔차제공

기반 F 통계량으로 두 모형을 비교한다.

$$\text{(제한)} \quad p_t = \alpha_0 + \sum_{k=1}^L \alpha_k p_{t-k} + \varepsilon_t, \quad (1)$$

$$\begin{aligned} \text{(비제한)} \quad p_t = & \beta_0 + \sum_{k=1}^L \beta_k p_{t-k} \\ & + \sum_{k=1}^L \gamma_k c_{t-k} + \eta_t, \end{aligned} \quad (2)$$

여기서 p_t 는 가격(필요 시 1차 차분), c_t 는 한 미디어 채널의 점수(필요 시 1차 차분), L 은 래그 길이이다. 채널 간 상호작용을 RQ1 단계에서 통제하지 않기 위해 본 절에서는 채널을 한 번에 하나씩만 투입한다 (다채널 동시 투입은 §4.6의 VAR 절에서 별도로 다룬다). 채널 시차계수 전체가 0이라는 귀무가설 $H_0: \gamma_1 = \dots = \gamma_L = 0$ 이 기각될 때, 해당 채널이 가격을 Granger 의미에서 선행한다고 판정한다.

래그 선택. 후보 래그를 $\{1, 2, 3, 4\}$ 로 두고 두 시계열의 이변량 VAR을 적합한 뒤, Schwarz [1978] 기준(BIC)이 최소화되는 래그를 자산-채널 조합별로 채택한다. 그래도 유의 결과가 전혀 관찰되지 않는 조합에 한해 보조 진단으로 $L = 5, 6$ 까지 확장하여 검정을 반복한다.

판정 기준. 본 연구는 유의성 판정을 raw p -값 하나로 단순화 한다. $p < 0.05$ 는 SIGNIFICANT, $0.05 \leq p < 0.10$ 은 MARGINAL(탐색적 참고), $p \geq 0.10$ 은 NOT_SIG로 표기한다. F 값 자체는 효과 크기를 가늠하기 위한 부수 지표로만 함께 보고하며, “ $F \geq 4.0$ ” 같은 비표준 임계값은 컷오프 자의성을 회피하기 위해 사용하지 않는다.

다중비교 보정에 관한 주.³

³본 단계에서 이루어지는 15회 검정에 Benjamini and Hochberg [1995]의 FDR 보정을 적용하면 일부 유의 판정이 약화될 수 있다. 그럼에도 raw p -값을 1차 판정 도구로 채택한 근거는 세 가지이다. 첫째, Granger 인과성을 활용한 응용 계량 문헌에서 단독 검정의 raw p -값 보고는 표준 관행에 속한다. 둘째, 본 연구의 검정 단위는 서로 다른 자산-채널 조합으로 구성되며, 동일 가설을 반복 표본으로 평가하는 구조가 아니다. 셋째, 본 단계의 일차목적이 후속 머신러닝에 투입할 채널의 선별이며, 지나치게 보수적인 FDR 적용은 잠재적으로 유용한 신호까지 과대 배제할 위험이 있다. 그럼에도 결과의 강건성 점검을 위해 BH 보정 결과를 부록 표로 함께 제시한다.

3.6 패널 Granger 인과성 검정 (Dumitrescu–Hurlin)

자산-평균 시계열을 사용하는 §3.5의 설계는 분석을 단순화하지만 두 가지 잠재적 약점을 갖는다. 첫째, 자산 내 아이템 5개의 시계열을 산술 평균함으로써 아이템 간 신호의 이질성을 측정 단계에서 이미 제거한다. 둘째, RQ3의 XG-Boost는 아이템 단위(15개 패널)로 학습되므로, Granger(자산 단위)와 분석 단위가 일치하지 않는다. 본 연구는 이 문제를 보완하기 위해 Dumitrescu and Hurlin [2012]의 패널 Granger 비인과성 검정을 추가 적용한다.

검정 형태. 자산 a 에 속한 아이템 $i \in \{1, \dots, N\}$ (본 연구에서 $N = 5$)에 대해 개별 Granger 회귀

$$p_{i,t} = \alpha_i + \sum_{k=1}^K \beta_{i,k} p_{i,t-k} + \sum_{k=1}^K \gamma_{i,k} c_{i,t-k} + \varepsilon_{i,t} \quad (3)$$

을 적합하고, 각 아이템에 대해 $H_{0,i}: \gamma_{i,1} = \dots = \gamma_{i,K} = 0$ 의 Wald (F) 통계량 W_i 를 산출한다. 정상성 처리(차분 여부)는 자산-평균 ADF 결과(표 4)와 동일한 규칙을 5개 아이템 모두에 일관 적용한다.

집계 통계량. 패널 평균 $\bar{W} = \frac{1}{N} \sum_{i=1}^N W_i$ 에 대해 Dumitrescu and Hurlin [2012]의 표준화량

$$\tilde{Z} = \sqrt{\frac{N}{2K}} \cdot \frac{T-3K-5}{T-3K-3} \left[\frac{T-3K-3}{T-3K-1} \bar{W} - K \right] \xrightarrow{a} \mathcal{N}(0, 1) \quad (4)$$

와 점근(asymptotic) 통계량

$$\bar{Z} = \sqrt{\frac{N}{2K}} (\bar{W} - K) \xrightarrow{a} \mathcal{N}(0, 1) \quad (5)$$

을 함께 산출한다. 본 연구의 표본은 $T = 48$ 로 유한하므로 유한표본 보정항을 포함한 $\tilde{Z}$ 를 주 통계량으로 보고하고, $\bar{Z}$ 는 부수적 비교 지표로 함께 제시한다. 양측이 아닌 단측 검정(상측)을 사용한다(W_i 가 비음수). 본 연구에서 $K \in \{1, 2\}$, $N = 5$, $T = 48$ 이며, 유한표본 보정의 정의역 조건 $T - 3K - 5 > 0$ 이 모두 충족된다.

판정 기준. §3.5와 동일하게 raw p -값 ($p_{\tilde{Z}}$) 기준 $p < 0.05$ 를 SIGNIFICANT, $0.05 \leq p < 0.10$ 를 MARGINAL로 분류한다. 자산-평균 Granger와의 일치/불일치(“평균이 놓친 신호” 대 “평균이 만든 거짓 양성”)는 결과 절에서 별도로 보고한다. 패널 검정 15회(3자산 $\times$ 5채널, 주 래그 $K = 1$)에 대한 BH 보정 결과도 함께 보고한다.

한계. 본 검정은 $N = 5$ 로 패널의 횡단면 차원이 작아 정규 근사가 비교적 약하다. DH 원론문은 N 이 작은 경우 잔차부트스트랩 변형의 사용을 권장하나, 본 연구는 보고의 명료성을 위해 표준 $\tilde{Z}$ 통계량을 사용하며 이 점을 한계로 명시한다.

3.7 자산별 채널 구성 비교 (Jaccard)

RQ2는 자산 유형 간에 선행 채널의 구성이 얼마나 다른지를 정량화하는 문제로 환원된다. 본 절은 각 자산 a 에 대해 SIGNIFICANT 판정을 받은 채널들만으로 집합 $S_a \subseteq \{\text{CH1}, \dots, \text{CH5}\}$ 를 정의하고, 두 자산 a, b 사이의 구성 유사도를 두 집합의 교집합과 합집합의 비

$$J(S_a, S_b) = \frac{|S_a \cap S_b|}{|S_a \cup S_b|}$$

로 측정한다. 본 정의는 자카드 계수의 표준 형태이며, 0(완전 이질) $\sim$ 1(완전 일치) 범위를 가진다. 후속 머신러닝 단계의 Model B는 MARGINAL 채널까지 포함하지만, RQ2의 목적이 “자산별 주요 선행 채널 구성”의 비교임을 고려하여 본 절은 보수적으로 SIGNIFICANT 채널만을 집합에 포함한다. 본 연구는 다음 임계를 채택한다.

- $J < 0.3$: 자산별 채널 구성이 다름 (RQ2 지지).
- $0.3 \leq J \leq 0.6$: 부분적 차이.
- $J > 0.6$: 구성 유사. 이 경우 F 통계량 크기와 래그 차이를 보조 지표로 활용해 결론을 수정한다.

3.8 XGBoost + SHAP + Diebold–Mariano 설계

데이터. XGBoost 단계에서는 z-score로 통일된 패널 (panel_monthly_scaled.csv)을 사용한다. 각 채널 점수는 전체 샘플의 평균·표준편차로 전역(global) 정규화한다. 교차검증 폴드별로 별도 정규화하지 않은 이유는 자산당 표본 크기($N = 48$)가 작아 폴드별 적합 시 오히려 추정 분산이 확대될 수 있기 때문이며, 한계 절에 명시한다.

타겟 변수. 월간 가격 방향성을 0/1로 정의한다.

$$y_t = \mathbb{I}(p_t > p_{t-1}).$$

이 정의에 따라 첫 달은 정의되지 않으므로 분석에서 제외한다(2022년 1월 15행 제거, 최종 705행).

통제 피처. 가격 자체의 자가상관과 추세를 흡수하기 위해 다음 4개 통제 피처를 모든 모형에 포함한다.

$$\begin{aligned} & \text{price_vs_ma3}_t, \quad \text{price_chg_lag1}_t, \\ & \text{price_chg_lag2}_t, \quad \text{price_chg_lag3}_t. \end{aligned}$$

모든 시차 변수는 shift를 통해 미래 누설(look-ahead)을 차단하였다.⁴

모형.

- **Model A (전 채널):** 통제 피처 + CH1~CH5.
- **Model B (Granger 선별):** 통제 피처 + 해당 자산에서 Granger 유의 또는 경계로 판정된 채널만.

이에 더해 결과 절에서는 두 가지 추가 검증을 수행한다. 첫째, Granger 선별과 독립적으로 SHAP 중요도 기반 채널 선별의 효과를 점검하는 **Model C**를 추정한다 (§4.9). 각 TimeSeriesSplit 폴드의 학습 구간에서만 Model A의 SHAP 중요도를 산출해 상위 2개 채널을 선택하므로, 채널 선택 단계에서 테스트 구

⁴1 개월 수익률을 l 개월 시차 이동한 `pct_change(1).shift(l)` 형태를 사용하여 누설을 방지하였다. 타겟 변수와 lag1 간 상관관은 -0.04 수준으로 누설이 없음을 확인하였다.

간 정보가 누설되지 않는다. 둘째, 본 연구의 자산·채널 구성에 직접 비교 가능한 선행 결과가 없다는 한계를 보완하기 위해, 기존 리셀 가격 예측 연구 [Raditya et al., 2021]가 사용한 기준 모형군을 본 연구와 동일한 데이터·검증 설계에 적용하는 벤치마크 비교를 수행한다 (§4.9).

학습·평가. 본 연구는 두 가지 보완적 평가 절차를 수행한다. 첫째, 분류 성능 평가로 XGBClassifier [Chen and Guestrin, 2016]를 TimeSeriesSplit($n_{\text{splits}} = 5$)으로 학습·검증하고 ROC-AUC를 산출한다. 둘째, 예측 정확도의 통계적 등가성 검정으로 XGBRegressor로 월별 평균 가격 (mean_price)을 예측한 뒤, TimeSeriesSplit($n_{\text{splits}} = 4$, $\text{test_size} = 6$)의 4개 폴드 전체 예측 오차를 합산하여 ($T = 24/\text{아이템}$) Diebold–Mariano 검정 [Diebold and Mariano, 1995]을 수행한다. DM 검정의 손실함수는 제곱오차 ($h = 1$, Newey–West 추정)이다. 두 절차는 각각 방향성 예측력과 수준 예측 오차의 등가성이라는 서로 다른 차원을 평가한다.⁵

RQ3 판정 기준.

- DM $p < 0.05$ 이고 부호가 Model B에 유리: **강한 RQ3 지지** (선별 채널이 전 채널보다 우수).
- DM $p > 0.10$: **약한 RQ3 지지**로 해석 (통계적으로 구분되는 손실 없이 채널 수 축소).
- DM $p < 0.05$ 이고 부호가 Model A에 유리: **RQ3 비지지** (Granger 선별의 정보 손실).
- DM $p \in [0.05, 0.10]$: 경계 수준으로 보고.

해석. 각 자산·모형에 대해 SHAP [Lundberg and Lee, 2017]로 채널별 평균 절대 SHAP 값 (global feature importance)을 산출하고, Granger F 순위와 SHAP 순위 간 일치/불일치를 비교한다. 두 순위가 체계적으로 어긋나는 채널은 결과 절에서 원인을 함께 논의한다. 본 절의 SHAP 분석은 분류 기준 Model A에서 산출하며, RQ3 DM 검정은 회귀 기준이므로 두 결

⁵본 연구가 DM을 회귀 기준으로 구현한 이유는 DM 검정이 원래 점예측 (point forecast) 오차 비교를 위해 설계되었기 때문이다. 분류 확률에 대한 Brier 점수 기반 DM은 결과 안정성이 더 낮아 주 분석 (Model A vs. B)에서는 제시하지 않으며, 분류 확률 비교가 목적인 Model C 추가 검증 (§4.9)에 한해 보고한다.

과는 동일 적합 모형이 아닌 동일 피처 집합 하 보완 지표로 해석된다(§5.4 참조).

재현성. 주 분석에서는 비교 공정성을 위해 두 모형에 동일한 고정 하이퍼파라미터 ($n_estimators=100$, $max_depth=3$, $learning_rate=0.05$) 를 적용하고 $random_state$ 를 42로 고정하였다. 단순 default 적합이 두 모형 중 한쪽에 우연히 더 유리하게 작용했을 가능성은 §4.9의 견고성 검토(Optuna TPE 기반 540회 베이지안 최적화)에서 별도로 점검한다. 분석 스크립트(데이터 수집, 점수 변환, ADF·Granger·DH·VAR 검정, XGBoost·SHAP·DM, 하이퍼파라미터 튜닝)는 본 연구의 공개 저장소에서 제공한다.⁶

다중공선성 사전 점검. 본 연구는 Granger 검정에서 채널을 한 번에 하나씩만 투입(단독 검정)하고, XGBoost는 트리 기반 모형으로 채널 간 선형 다중공선성에 비교적 둔감하다. 따라서 본 설계는 VIF 진단을 필요로 하지 않으나, 다중 채널을 동시 투입한 회귀 기반 후속 연구에서는 CH2(보도량)와 CH3(감성)의 상관, CH4와 CH5의 상관을 사전 점검할 것을 권고한다. 실제 채널 간 상관행렬은 부록 C(표 20)에 제시하였으며, cards의 CH2-CH3 상관계수가 0.763으로 높은 점이 확인되었다. 본 연구의 단독 검정 설계에서는 해당 다중공선성이 Granger 결과에 직접 영향을 미치지 않는다.

4 결과

4.1 기술 통계

표 3는 15개 아이템의 자산별 주요 변수에 대한 기술 통계량이다. 가격($mean_price$)과 채널 점수(CH1-CH5)는 각 자산 내 아이템 240개 관측치(아이템 5개 $\times$ 48개월)의 요약값을 나타낸다.

스니커즈는 가격 표준편차(565.0)가 평균(466.4)을 초과하여 분산이 크며, 이는 Travis Scott Jordan 1과 같이 가격이 매우 높은 아이템과 상대적으로 낮은 아이템이 공존하는 데 기

인한다. 카드와 레고는 스니커즈보다 낮은 변동성을 보인다. CH1(Google Trends)은 카드에서 평균 42.5로 가장 높고, 레고에서 20.3으로 가장 낮다. 이는 레고 단종 세트의 검색 관심도가 상대적으로 낮음을 반영하며, $lego_porsche$ 와 $lego_bugatti$ 의 0값 비율이 높은 점과 일관된다.

4.2 ADF 정상성 검정

3개 자산 $\times$ 6개 시계열(가격 + 채널 5개) = 18개 시계열에 대해 ADF 검정을 수행하였다(표 4). 자산별 가격 시계열과 일부 채널 점수는 수준 값에서 단위근을 기각하지 못하여 1차 차분 후 Granger 검정에 투입하였다.

4.3 RQ1: Granger 인과성 검정

자산별 대표 시계열을 대상으로 5개 채널에 대한 단독 Granger 검정을 수행한 결과는 표 5와 같다. 15회 검정 중 유의(SIGNIFICANT, $p < 0.05$) 4회, 경계(MARGINAL, $0.05 \leq p < 0.10$) 1회, 비유의(NOT_SIG) 10회로 나타났다.

스니커즈에서는 세 채널—CH3(뉴스 감성, $F = 13.38$, $p = 0.001$), CH4(YouTube 조회 수, $F = 4.73$, $p = 0.035$), CH1(Google Trends, $F = 3.47$, $p = 0.041$)—이 가격을 유의 수준에서 선행하는 것으로 관찰되었다. CH3의 F 통계량은 15회 검정 중 가장 큰 효과 크기를 보였으나, 표본 크기 ($N = 48$)와 다중 검정 구조를 감안할 때 단일 통계량에 과도한 해석을 부여하기는 어렵다. 카드에서는 CH1(Google Trends, $F = 8.42$, $p = 0.006$)이 유의하게 선행하였고, 레고에서는 CH1이 경계 수준에 머물렀다($F = 3.92$, $p = 0.054$).

RQ1 결론: 일부 채널이 자산 유형에 따라 리셀 가격을 Granger 의미에서 선행하는 잠정적 증거가 관찰되었다. 선행 강도와 채널 구성은 채널-자산 조합에 따라 상이하다. 단, 본 결과는 다중 검정 보정 및 표본 크기 제약 하에서 탐색적 발견으로 해석되어야 하며, 견고성 검토를 위해 부록 A에 BH 보정 결과를 함께 제시한다.

⁶저장소 URL은 출판 시 공개. 핵심 디렉토리: `scripts/`(수집·전처리·검정), `results/`(결과 CSV·그림), `paper/`(LaTeX 원본).

표 3: 자산별 기술 통계량 (아이템-월 단위, 자산당 $n = 240 = \text{아이템 } 5\text{개} \times 48\text{개월}$). 각 자산군 내 가격 (mean_price)과 다섯 채널 점수(CH1-CH5)의 평균·표준편차·최솟값·최댓값을 보고한다. 스니커즈의 가격 표준편차(565.0)가 평균(466.4)을 초과하는 것은 Travis Scott Jordan 1 등 고가 아이템과 상대적으로 낮은 가격대의 아이템이 공존하는 데 기인하며, 카드와 레고는 스니커즈보다 낮은 분산을 보인다. CH1(Google Trends)은 카드에서 평균 42.5로 가장 높고 레고에서 20.3으로 가장 낮는데, 이는 일부 레고 아이템(lego_porsche, lego_bugatti)에서 0값이 다수 나타나는 점과 일관된다. CH2·CH3는 정규화 방식이 서로 다르므로 절대값 크기보다는 자산 간 상대 비교로 해석해야 하며, CH4는 아이템 내 z-score 변환값이므로 자산 평균이 약 0, 표준편차가 약 1로 수렴한다.

자산	변수	평균	표준편차	최솟값	최댓값
sneakers	가격 (USD)	466.4	565.0	60.5	2077.5
	CH1 Google Trends	30.2	22.8	1.2	95.5
	CH2 뉴스 보도량	0.07	0.21	0.00	1.00
	CH3 뉴스 감성	0.001	0.005	-0.005	0.070
	CH4 YT 조회수	0.00	1.00	-3.03	1.86
	CH5 댓글 감성	0.007	0.053	-0.437	0.164
cards	가격 (USD)	374.8	344.7	81.0	1900.0
	CH1 Google Trends	42.5	18.7	0.0	93.2
	CH2 뉴스 보도량	0.14	0.25	0.00	1.00
	CH3 뉴스 감성	0.006	0.012	-0.002	0.074
	CH4 YT 조회수	0.00	1.00	-4.31	1.70
	CH5 댓글 감성	0.025	0.035	-0.071	0.183
lego	가격 (USD)	442.5	216.0	119.5	1136.5
	CH1 Google Trends	20.3	16.2	0.0	67.2
	CH2 뉴스 보도량	0.07	0.18	0.00	1.00
	CH3 뉴스 감성	0.002	0.008	-0.003	0.074
	CH4 YT 조회수	0.00	1.00	-5.09	4.09
	CH5 댓글 감성	0.036	0.082	-0.240	0.423

주. CH4는 아이템 내 z-score 변환값이므로 평균 ≈ 0 , 표준편차 ≈ 1 .
CH2·CH3 범위는 정규화 방식에 따라 다름 (§3.3 참조).

4.4 RQ1 래그 견고성 검토

BIC로 선택된 최적 래그 하나에만 의존하면 결과가 특정 래그 길이에 민감할 수 있다. 이를 보완하기 위해 래그를 $L = 1, 2, 3$ 으로 각각 고정한 뒤 동일한 Granger 검정을 반복하여 주요 발견의 래그 견고성을 확인하였다(표 6).

표 6에서 sneakers의 CH3(뉴스 감성)는 $L = 1, 2, 3$ 전 래그에서 일관되게 $p < 0.001$ 로 유의하여 가장 견고한 발견임이 확인된다. cards의 CH1(Google Trends)도 $L = 1, 2$ 에서 유의하다. 반면 sneakers의 CH1($L = 2$ 에서만 유의)과 CH4($L = 1$ 에서만 유의)는 래그 선택에 민감하여, 해당 판정의 신뢰도가 상대적으로 낮다.

주목할 만한 추가 관찰로, sneakers의 CH5(YouTube 댓글 감성)가 $L = 1$ 에서는 비유의($p = 0.764$)였으나 $L = 2, 3$ 에서 유의($p = 0.016, p = 0.009$)하다. BIC는 $L = 1$ 을 최적 래그로 선택하였으므로 주 분석에서는

비유의로 보고되었으나, 댓글 감성의 가격 선행 효과가 2~3개월 지연되어 나타날 가능성을 탐색적으로 시사한다. 이 발견은 주 분석 결론을 변경하지 않지만 향후 래그 범위를 확장한 후속 연구의 동기를 제공한다.

레고에서는 모든 래그·채널 조합에서 일관되게 비유의로 나타났다.

4.5 RQ1 패널 견고성 검토 : Dumitrescu-Hurlin 검정

§4.3과 §4.4의 검정은 자산 5개 아이템의 시계열을 평균한 대표 시계열에 기반하므로, 아이템 간 신호의 이질성을 측정 단계에서 이미 제거한다. 본 절에서는 §3.6에서 정의한 Dumitrescu and Hurlin [2012] 패널 검정을 자산 내 5개 아이템을 횡단면으로 두고 동일한 (자산, 채널) 조합에 적용하여, 자산-평균 Granger 결과가 패널 차원에서도 유지되는지를 검토한다. 자산 단위 RQ1

표 4: Augmented Dickey–Fuller (ADF) 정상성 검정 결과 요약. 자산별 대표 시계열(아이템 5개 월별 평균)을 대상으로 가격(mean_price)과 다섯 채널 점수(CH1–CH5), 총 18개 시계열에 대해 ADF 검정을 수행하였다. 귀무가설은 “시계열이 단위근을 갖는다(비정상)”이며, $p < 0.05$ 이면 정상성을 기각하지 못하지 않는다. 수준값에서 비정상으로 판정된 시계열은 1차 차분 후 재검정 하였으며, “차분 적용” 열의 “O”는 Granger 검정에 차분된 시계열을 투입함을 의미한다. 가격 시계열은 세 자산 모두에서 1차 차분 후 정상화되었고, GDELT 계열(CH2·CH3)과 YouTube 댓글 감성(CH5)은 대부분 수준값에서 이미 정상이었다. sneakers의 score_ch1은 1차 차분 후에도 $p = 0.120$ 으로 단위근을 엄밀히 기각하지 못한 사례로, 한계 절 (§5.4)에서 추가 논의한다.

자산	변수	ADF 통계량	p (수준)	p (1차 차분)	차분 적용
sneakers	mean_price	−2.131	0.232	< 0.001	O
	score_ch1	−0.297	0.926	0.120	O [†]
	score_ch2	−5.646	< 0.001	—	X
	score_ch3	−3.558	0.007	—	X
	score_ch4	−3.973	0.002	—	X
	score_ch5	−4.361	< 0.001	—	X
cards	mean_price	−2.046	0.267	0.007	O
	score_ch1	−2.175	0.216	< 0.001	O
	score_ch2	−4.879	< 0.001	—	X
	score_ch3	−1.834	0.364	< 0.001	O
	score_ch4	−1.958	0.305	< 0.001	O
	score_ch5	−3.902	0.002	—	X
lego	mean_price	−2.511	0.113	< 0.001	O
	score_ch1	−1.154	0.693	< 0.001	O
	score_ch2	−5.919	< 0.001	—	X
	score_ch3	−5.817	< 0.001	—	X
	score_ch4	−6.595	< 0.001	—	X
	score_ch5	−3.001	0.035	—	X

[†] 1차 차분 후 $p = 0.120$ 으로 엄밀한 정상성 미확인.

실질적 자기상관 감소 확인 후 차분값 사용(한계 절 참조).

결론과 RQ3의 아이템 단위 XGBoost 사이의 분석 단위 불일치도 본 절을 통해 부분적으로 완화된 다.

표 7는 세 가지 패턴을 드러낸다. 첫째, 진정한 자산-공통 신호로서 cards-CH1은 5개 아이템 모두에서 $F \geq 1.9$ 의 양의 신호를 보이며 $\tilde{Z} = 3.75$ ($p < 0.001$)로 가장 강건하다. 본 발견은 평균 Granger와 DH 양쪽에서 모두 유의이며, BH 보정 후에도 유지된다. 둘째, 평균이 만든 거짓 양성 가능성으로서 sneakers-CH3(뉴스 감성)는 주 분석 (§4.3)에서 $F = 13.38$, $p < 0.001$ 로 본 연구의 가장 강한 발견이었으나, 아이템 단위로 분해하면 5개 모두 $F < 0.5$ 로 어떤 개별 아이템에서도 인과성을 보이지 않는다. DH 검정에서는 $\tilde{Z} = -1.15$ ($p = 0.876$)로 비유의 판정이 명확하다. 이는 자산-평균 과정에서 아이템 간 잡음이 상쇄되며 인공적 공통 신호가 증폭되었을 가능성을 시사한다. 셋째, 평균이 놓친 신호로서

cards-CH2는 자산-평균에서 비유의 ($p = 0.398$)였으나 DH에서는 유의 ($p = 0.032$)이다. 다만 아이템별 F를 보면 Umbreon($F = 9.03$)에 의한 단일 주도이므로 자산 전체로의 일반화는 제한적이다.

§4.3의 자산-평균 BH 보정 결과(부록 §A)는 sneakers-CH3와 cards-CH1만을 SIGNIFICANT로 유지하였다. DH 검정의 15회 (주래 그 $K = 1$) BH FDR 보정 결과는 **sneakers-CH4** ($p_{\text{BH}} = .036$)와 **cards-CH1** ($p_{\text{BH}} = .001$) 2개만을 유지한다. 즉 BH 보정 단계에서 “살아남는 채널”이 자산-평균 ({sneakers-CH3, cards-CH1})과 DH ({sneakers-CH4, cards-CH1}) 간에 일부 교체되며, 일관되게 살아남는 유일한 발견은 **cards-CH1**이다. 본 연구는 분석 단위가 일치하지 않는 두 검정 모두에서 BH 보정 후에도 유지되는 cards-CH1을 자산 차원의 가장 신뢰할 수 있는 미디어 선행 채널로 해석한다.

표 5: 단독(bivariate) Granger 인과성 검정 결과 (raw p -값, BIC 기반 래그 선택). 자산-월 단위 대표 시계열에 대해 3 자산 $\times$ 5 채널 = 총 15회의 단독 Granger 검정을 수행한 결과이다. “래그” 열은 후보 $L \in \{1, 2, 3, 4\}$ 중 이변량 VAR의 BIC를 최소화하는 값이며, F 는 비제한 모형에서 채널 시차 계수 전체에 대한 결합 검정통계량, p 는 그 raw p -값이다. 판정 기준은 본문 §3.5에 따라 $p < 0.05$ 이면 SIGNIFICANT, $0.05 \leq p < 0.10$ 이면 MARGINAL, $p \geq 0.10$ 이면 NOT_SIG으로 보고하며, F 통계량은 효과 크기의 보조 지표로만 사용 하고 판정 기준에는 사용하지 않는다. 15회 검정 중 SIGNIFICANT가 4회 (sneakers의 CH1·CH3·CH4와 cards의 CH1), MARGINAL이 1회 (lego CH1), NOT_SIG가 10회로 관찰되었으며, Benjamini-Hochberg FDR 보정 ($q = 0.05$) 적용 시 SIGNIFICANT는 sneakers CH3와 cards CH1의 2회로 축소된다(부록 표 18 참조).

자산	채널	래그	F	p	판정
sneakers	CH1 Google Trends	2	3.47	0.041	SIGNIFICANT
	CH2 뉴스 보도량	1	1.55	0.220	NOT_SIG
	CH3 뉴스 감성	1	13.38	0.001	SIGNIFICANT
	CH4 YouTube 조회수	1	4.73	0.035	SIGNIFICANT
	CH5 댓글 감성	1	0.09	0.764	NOT_SIG
cards	CH1 Google Trends	1	8.42	0.006	SIGNIFICANT
	CH2 뉴스 보도량	1	0.73	0.398	NOT_SIG
	CH3 뉴스 감성	1	1.41	0.242	NOT_SIG
	CH4 YouTube 조회수	1	0.25	0.622	NOT_SIG
	CH5 댓글 감성	1	0.61	0.438	NOT_SIG
lego	CH1 Google Trends	1	3.92	0.054	MARGINAL
	CH2 뉴스 보도량	1	0.32	0.576	NOT_SIG
	CH3 뉴스 감성	1	0.40	0.530	NOT_SIG
	CH4 YouTube 조회수	1	1.83	0.183	NOT_SIG
	CH5 댓글 감성	1	0.17	0.680	NOT_SIG

본 절의 결과는 §4.3의 자산-평균 결론을 부분적으로 수정한다. 특히 sneakers-CH3는 §4.4의 래그 견고성 검토에서 $L = 1, 2, 3$ 모두 유의(✓)였음에도 패널 차원에서는 인과성이 검출되지 않으며, 후속 IRF(§4.7)에서 관찰된 음(-)의 부호가 자산-평균 과정의 산물일 가능성도 배제할 수 없다. 본 절을 한계 절(§5.4)의 “분석 단위 불일치” 항목과 함께 종합하여, 본 연구는 자산 단위 결론을 탐색적 수준으로 일관 보고한다.

4.6 RQ1 다변수 견고성 검토: VAR 블록 인과 검정

§4.3의 단독 Granger와 §4.5의 DH 패널 검정은 모두 채널을 한 번에 하나씩만 투입한다. 본 표본은 채널 간 상관이 일부 강하므로(예: cards에서 CH2-CH3 $r = 0.763$, 부록 §C), 단독 검정의 유의 판정이 다른 채널의 효과를 흡수했을 가능성을 배제할 수 없다. 본 절은 자산-평균 시계열에 5개 채널과 가격을 동시에 투입한 6변수 VAR을 적합한 뒤, 두 종류의 인과 검정을 수행한다

(Lütkepohl, 2005, §3.6):

- **블록 검정.** 귀무가설 H_0 : 5개 채널이 동시에 가격을 Granger-cause 하지 않는다. 단일 F 통계량으로 자산 차원의 “채널군 전체 효과”를 평가하며, 단독 5회 검정의 다중비교 문제도 통합 해결한다.
- **개별 검정(다채널 통제).** 귀무가설 $H_{0,c}$: 채널 c 가 다른 4개 채널을 통제한 상태에서 가격을 Granger-cause 하지 않는다. 단독 검정과 동일한 형태로 자산 $\times$ 채널 = 15개를 보고하되, 다중공선성 통제 후의 순수 효과를 측정한다.

래그는 단독 검정과 동일하게 VAR BIC로 선택 ($L = 1$, 세 자산 공통). 유효 표본 $T = 47$, 6변수 모형에서 분모 자유도 234.

표 8의 블록 검정에서 sneakers($p = .0009$)와 cards($p = .0017$)는 채널군 전체가 동시에 가격을 선행한다는 강한 증거를 제공하며, lego는 비유의로 §4.8의 RQ2 결론을 강화한다. 표 9의 개별 검정에서는 다른 4채널을 통제한 후에도 **sneakers CH3**($F = 12.12$, $p_{BH} = .0045$)와

표 6: Granger 검정의 래그 견고성 검토: 래그를 $L \in \{1, 2, 3\}$ 으로 각각 고정한 재검정 결과. 각 셀은 “ $F[p]$ ” 형식으로 보고하며, 굵음 표기는 $p < 0.05$ (유의), $\dagger$ 는 $0.05 \leq p < 0.10$ (경계)를 나타낸다. “견고성” 열의 $\checkmark$ 는 2개 이상 래그에서 $p < 0.05$ 로 일관된 유의가 확인된 경우, Δ 는 단 하나의 래그에서만 유의해 래그 선택에 민감한 경우, —는 모든 래그에서 비유의로 일관된 경우를 나타낸다. 주 분석(표 5)은 BIC가 선택한 단일 최적 래그에 의존하므로, 본 표는 어떤 발견이 래그 선택에 견고하고 어떤 발견이 그렇지 않은지를 판별하기 위한 보완 검증이다. sneakers의 CH3(뉴스 감성)는 세 래그 모두에서 $p < 0.01$ 로 가장 견고한 발견이며, cards의 CH1(Google Trends)도 $L = 1, 2$ 에서 일관 유의로 견고하다. 반면 sneakers의 CH1·CH4는 단일 래그에서만 유의하여 래그 민감성이 확인 된다. 주목할 만한 추가 관찰로, sneakers의 CH5는 BIC 최적 래그 $L = 1$ 에서는 비유의이나 $L = 2, 3$ 에서 유의하여 2-3개월 지연된 선행 효과의 가능성을 탐색적으로 시사한다.

자산	채널	$L = 1$	$L = 2$	$L = 3$	견고성
sneakers	CH1 Google Trends	0.50 [.483]	3.47 [.041]	2.30 [.093] $\dagger$	Δ
	CH2 뉴스 보도량	1.55 [.220]	0.93 [.401]	0.80 [.504]	—
	CH3 뉴스 감성	13.38 [<.001]	7.02 [.002]	6.65 [.001]	$\checkmark$
	CH4 YouTube 조회수	4.73 [.035]	2.79 [.073] $\dagger$	1.45 [.245]	Δ
	CH5 댓글 감성	0.09 [.764]	4.58 [.016]	4.47 [.009]	$\checkmark$
cards	CH1 Google Trends	8.42 [.006]	4.56 [.016]	2.44 [.080] $\dagger$	$\checkmark$
	CH2 뉴스 보도량	0.73 [.398]	1.97 [.153]	3.13 [.037]	—
	CH3 뉴스 감성	1.41 [.242]	1.92 [.161]	1.05 [.380]	—
	CH4 YouTube 조회수	0.25 [.622]	0.65 [.530]	2.99 [.043]	—
	CH5 댓글 감성	0.61 [.438]	0.54 [.588]	1.81 [.162]	—
lego	CH1 Google Trends	3.92 [.054] $\dagger$	1.24 [.301]	2.04 [.126]	—
	CH2 뉴스 보도량	0.32 [.576]	0.17 [.848]	0.33 [.805]	—
	CH3 뉴스 감성	0.40 [.530]	0.04 [.958]	0.09 [.963]	—
	CH4 YouTube 조회수	1.83 [.183]	0.22 [.803]	0.69 [.561]	—
	CH5 댓글 감성	0.17 [.680]	0.78 [.466]	0.93 [.434]	—

주. 굵음: $p < 0.05$. $\dagger$: $0.05 \leq p < 0.10$.

$\checkmark$: 2개 이상 래그에서 $p < 0.05$ (견고). Δ : 1개 래그에서만 $p < 0.05$ (래그 민감). —: 모든 래그 비유의.

cards CH1($F = 16.82$, $p_{BH} = .0009$)이 BH 보정을 통과한다. 주목할 점은 단독 검정에서 유의 또는 경계였던 *sneakers* CH1·CH4와 *cards* CH2가 다중공선성 통제 후 NS/MARG로 약화된다는 것이다. 이는 단독 판정의 유의성이 다른 채널 효과의 일부 흡수에 의존했을 가능성을 시사한다.

세 검정의 종합 정리. 단독 Granger, DH 패널 검정, VAR 다채널 통제 검정 세 가지 모두에서 BH 보정 후에도 유지되는 발견은 **cards-CH1** 한 조합으로 좁혀진다. *sneakers*-CH3는 단독·VAR에서 강하지만 DH에서 약화되며, 이는 자산-평균 수준의 집합적 효과는 존재하지만 5개 아이템 모두에 균등하게 분포하지는 않음으로 해석된다. *sneakers*-CH4는 DH에서만 BH 통과하므로 단독 검정에서는 평균 효과가 약하지만 일부 아이템에서 강한 신호가 존재하는 패턴이다. 세 검정의 교집합 발견을 표 10로 정리한다.

4.7 충격반응함수 분석

§4.3의 Granger 검정은 “채널이 가격을 선행하는가”라는 존재 여부를 판정하지만, 선행 효과의 부호와 지속 기간은 드러내지 않는다. 본 절에서는 BH 보정에서도 유의가 유지된 두 조합—*sneakers*의 CH3 뉴스 감성과 *cards*의 CH1 Google Trends—에 대해 양변수 VAR을 추정하고 직교화 충격반응함수(Orthogonalised IRF; Lütkepohl, 2005)를 산출하여 동적 반응을 가시화한다.

사양. 각 (자산, 채널) 쌍에 대해 가격과 채널 점수를 §3.4의 정상성 처리(필요 시 1차 차분) 후 양변수 VAR로 결합한다. 래그는 §4.3의 BIC 선택값을 따른다($L = 1$). 식별은 Cholesky 분해를 사용하며 채널이 가격을 선행한다는 가설에 따라 (채널, 가격) 순서로 정렬한다. 신뢰구간은 잔차 잭나이프 부트스트랩(1,000회 복원추

표 7: Dumitrescu–Hurlin 패널 Granger 검정 결과(주 래그 $K = 1$, $N = 5$ 아이템 $\times T = 48$). “개별 F ”는 자산 내 5개 아이템 각각에 대한 Granger F-통계량, $\bar{W}$ 는 그 평균, $\hat{Z}$ 는 유한표본 보정된 DH 표준화량, $p_{\hat{Z}}$ 는 단측 p-값이다. “평균 Granger”는 표 5의 자산-평균 Granger 결과 p-값이며, “일치”는 DH와 평균 Granger의 유의 판정 일치 여부를 나타낸다($\rightarrow$ 는 판정 변화 방향). DH 검정은 평균에서 가장 강했던 sneakers–CH3가 어느 아이템에서도 인과성을 보이지 않음을 드러내(평균이 만든 거짓 양성 가능성), 반대로 평균에서 비유의였던 cards–CH2는 Umbreon 1개 아이템의 강한 신호로 DH에서 유의로 판정된다(평균이 놓친 신호). 가장 안정적인 발견은 cards–CH1로, 5개 아이템 모두에서 $F \geq 1.9$ 의 일관된 양의 신호를 보인다.

자산	채널	개별 F (아이템 5개)	$\bar{W}$	$\hat{Z}$	$p_{\hat{Z}}$	Granger→DH
sneakers	CH1 Google Trends	2.61 / 0.01 / 0.36 / 0.21 / 0.01	0.64	−0.59	.722	MARG → NS
	CH2 뉴스 보도량	1.19 / 0.04 / 2.65 / 2.36 / 0.26	1.30	+0.36	.358	NS → NS (동일)
	CH3 뉴스 감성	0.50 / 0.02 / 0.21 / 0.25 / 0.26	0.25	−1.15	.876	SIG → NS
	CH4 YouTube 조회수	1.04 / 9.61 / 1.60 / 1.83 / 0.19	2.85	+2.59	.005	SIG → SIG
	CH5 댓글 감성	0.83 / 6.20 / 0.54 / 0.77 / 1.94	2.06	+1.45	.073 [†]	NS → MARG
cards	CH1 Google Trends	3.55 / 1.95 / 1.99 / 7.98 / 2.80	3.65	+3.75	< .001	SIG → SIG
	CH2 뉴스 보도량	0.27 / 9.03 / 0.04 / 1.46 / 0.90	2.34	+1.86	.032	NS → SIG
	CH3 뉴스 감성	0.72 / 4.28 / 0.08 / 0.63 / 0.03	1.15	+0.15	.441	NS → NS (동일)
	CH4 YouTube 조회수	0.53 / 0.35 / 0.02 / 0.07 / 0.26	0.25	−1.15	.875	NS → NS (동일)
	CH5 댓글 감성	1.10 / 4.20 / 4.43 / 0.84 / 0.02	2.12	+1.54	.062 [†]	NS → MARG
lego	CH1 Google Trends	0.00 / 5.71 / 0.07 / 0.26 / 1.18	1.44	+0.57	.284	MARG → NS
	CH2 뉴스 보도량	0.23 / 3.74 / 0.82 / 0.19 / 0.25	1.04	−0.00	.502	NS → NS (동일)
	CH3 뉴스 감성	0.05 / 4.41 / 0.34 / 0.00 / 0.00	0.96	−0.12	.549	NS → NS (동일)
	CH4 YouTube 조회수	0.00 / 1.41 / 0.02 / 1.32 / 2.45	1.04	−0.01	.506	NS → NS (동일)
	CH5 댓글 감성	0.05 / 0.32 / 2.40 / 0.00 / 0.83	0.72	−0.47	.681	NS → NS (동일)

주. 굵음: $p < 0.05$ (SIG). †: $0.05 \leq p < 0.10$ (MARG). 굵게 표시된 개별 F 는 해당 아이템에서 $F > 5$ 인 경우.

개별 F 의 아이템 순서: sneakers={jordan1, panda, yeezy, travis, nb550}, cards={charizard1, umbreon, rayquaza, pikachu, charizard2}, lego={falcon, hogwarts, titanic, porsche, bugatti}.

표 8: 자산-평균 시계열의 6변수 VAR에서 5채널 → 가격 블록 Granger 검정 ($L = 1$, 분자 $df=5$, 분모 $df=234$). sneakers와 cards는 채널군 전체가 동시에 가격을 선행한다는 결합 가설이 강하게 지지되며, lego는 비유의로 판정되어 §4.8의 RQ2 결론(자산별 분화)을 강화한다.

자산	F	p	판정
sneakers	4.29	0.0009	SIG
cards	4.01	0.0017	SIG
lego	1.45	0.206	NS

출; seed=42) 분위수로 산출하였다.⁷

⁷statsmodels v0.14 VAR. irf().errband_mc() 구현이 본 분석 환경에서 상하한이 동일하게 반환되는 문제를 보였으므로, Lütkepohl(2005, §3.5)에 따른 잔차부트스트랩을 직접 구현하였다. 스크립트는 scripts/run_irf.py 참조.

결과. 그림 1는 두 충격반응 패턴이 모두 단기 선행 + 빠른 감쇄라는 공통 구조를 보임을 나타낸다. 동시에 부호의 방향은 자산-채널 조합에 따라 정반대로 나타난다.

cards–CH1. Google Trends 1 SD 상승 시 1개월 후 가격 차분이 +10.80 달러 (CI [+3.59, +17.55]), 2개월 후 +6.03 (CI [+0.54, +10.95])로 유의한 양의 반응을 보인다. 이는 Da et al. [2011]의 “검색 관심 → 단기 가격 상승 압력” 패턴과 부호가 일치하며, 트레이딩 카드 시장에서 검색 관심도가 매수 수요의 선행 지표로 기능할 수 있음을 시사한다.

sneakers–CH3. 뉴스 감성 1 SD 상승 시 1개월 후 가격 차분이 −2.82 달러 (CI [−4.38, −1.23])로 유의한 음의 반응을 보인다. Granger 검정은

표 9: 6변수 VAR 내 개별 채널의 가격 Granger 인과 검정 (다른 4채널 통제 후, $L = 1$). 굵음은 BH FDR 보정 후에도 $p < 0.05$ 를 유지하는 발견이다. 단독 Granger 결과와 비교하면, *sneakers* CH3와 *cards* CH1이 다중공선성 통제 후에도 강하게 유지되어 가장 견고한 발견임이 재확인된다. 단독에서 유의했던 sneakers CH1과 CH4는 다른 채널 통제 후 NS/MARG로 약화되어, 단독 판정이 다른 채널 효과의 흡수에 부분적으로 의존했을 가능성을 시사한다.

자산	채널	F	p	p_{BH}	판정
sneakers	CH1 검색	1.54	.216	.299	NS
	CH2 뉴스량	0.14	.713	.714	NS
	CH3 뉴스감성	12.12	.0006	.0045	SIG
	CH4 YT조회수	2.91	.089 [†]	.252	MARG
	CH5 댓글감성	1.52	.219	.299	NS
cards	CH1 검색	16.82	<.001	.0009	SIG
	CH2 뉴스량	2.71	.101	.252	NS
	CH3 뉴스감성	1.39	.239	.299	NS
	CH4 YT조회수	2.19	.140	.262	NS
	CH5 댓글감성	3.08	.081 [†]	.252	MARG
lego	CH1 검색	4.37	.038	.189	SIG(raw)→NS(BH)
	CH2 뉴스량	1.42	.235	.299	NS
	CH3 뉴스감성	0.15	.703	.714	NS
	CH4 YT조회수	2.39	.124	.262	NS
	CH5 댓글감성	0.13	.714	.714	NS

주. †: $0.05 \leq p < 0.10$.

BH 보정은 15개 검정에 일괄 적용.

표 10: 세 인과 검정의 BH 보정 후 유의 채널 일치 표. ● = SIG, ○ = MARG, — = NS. 세 검정 모두에서 일관되게 유의한 발견은 *cards*—CH1이 유일하며, 본 연구는 이를 가장 신뢰할 수 있는 미디어 선행 채널로 보고한다.

자산	채널	단독	DH	VAR
sneakers	CH3 뉴스감성	●	—	●
sneakers	CH4 YT조회수	—	●	○
cards	CH1 검색	●	●	●

주. 단독은 raw $p < 0.05$ 그리고 BH 통과 기준.
단독 Granger에서 BH 통과한 sneakers CH3·
cards CH1만 표기.

부호를 식별하지 않으므로 본 음의 부호는 IRF에서 처음 드러난 결과이다. 이는 다음 두 경로로 해석 가능하다. 첫째, 긍정 뉴스가 종종 공식 재발매·콜라보 발표와 동시에 발생하는데, 이러한 발표는 신규 공급 신호로 작용하여 리셀 프리미엄을 단기적으로 압축할 수 있다(공급 충격 경로). 둘째, GDELT 톤은 도메인 특화 어휘(스니커즈 “hype”, “GR”) 대신 일반 뉴스 어휘의 감성을 측정하므로, 측정 노이즈가 부호에 영향을 줄 가능성도 배제할 수 없다(§5.4 참조). 두 경로 중 어느 것이 우세한지는 본 표본만으로는 식별 불가하며, 향후 도메인 특화 사전 또는 발표 이벤트 더미와의 결합 분석이 필요하다.

공통 패턴. 두 채널 모두 1~2개월 선행 + 4개월 내 소멸의 단기 충격 구조를 보인다. 이는 미디어 신호가 지속적 가격 추세보다는 국지적 수급 충격으로 작용한다는 해석과 부합하며, §4.9의 RQ3 결과(전 채널 모형 대비 절제된 우수성)와도 일관된다.

4.8 RQ2: 자산별 유의 채널 구성 비교

SIGNIFICANT 판정 채널만을 자산별 유의 채널 집합으로 정의하면 다음과 같다.

- 스니커즈: $S_{\text{sneakers}} = \{\text{CH1, CH3, CH4}\}$
- 카드: $S_{\text{cards}} = \{\text{CH1}\}$





그림 1: BH 보정 후 유의 채널에 대한 직교화 충격반응함수(95% 잔차 부트스트랩 신뢰구간). **왼쪽:** sneakers의 뉴스 감성(CH3) 1 표준편차 충격에 대한 차분 가격(ΔP_t)의 12개월 반응. 1개월 시점에 -2.82 (CI $[-4.38, -1.23]$)로 가장 큰 음의 반응을 보이며 4개월 내 0으로 감쇄한다. **오른쪽:** cards의 Google Trends(CH1) 1차 차분 충격에 대한 차분 가격의 반응. 1~2개월에서 양의 반응이 유의하며($+10.80, +6.03$, 두 CI 모두 0을 포함하지 않음), 3개월 이후 빠르게 감쇄한다. 횡축은 충격 후 경과 월, 음영은 95% 부트스트랩 신뢰구간이다.

- 레고: $S_{\text{lego}} = \emptyset$

세 자산쌍의 Jaccard 유사도는 표 11와 같다.

세 자산쌍 중 sneakers-cards는 $J = 0.333$ 으로 방법론 절의 “부분적 차이”($0.3 \leq J \leq 0.6$) 구간에 속하며, 두 자산이 모두 CH1(Google Trends)에서 선행성을 공유한다. 나머지 두 자산쌍은 $J = 0.000$ 으로 완전히 이질적이다.

RQ2 결론: 미디어 채널의 유의 구성은 자산 유형 간에 대체로 상이하며, 특히 레고는 다른 두 자산과 공통 채널을 공유하지 않는다. 단, sneakers와 cards는 CH1(Google Trends)을 공통 선행 채널로 가져 부분적 중복이 존재한다. 따라서 RQ2는 대체로 지지되되, 검색 트렌드(CH1)는 자산 간 공통적 선행 신호일 가능성이 있다.

4.9 RQ3: XGBoost 예측 검증 및 Diebold–Mariano 검정

Model A(전 채널)와 Model B(Granger 선별 채널)를 TimeSeriesSplit ($n_{\text{splits}} = 4$, $\text{test_size} = 6$)으로 학습하고, 4개 폴드 전체의 예측 오차를 합산하여($T = 24/\text{아이템}$) Diebold–Mariano 검정을 수행하였다.⁸ 결과는 표 12와 같다.

15개 아이템 중 11개(73%)에서 Model A와 B 간 통계적으로 유의한 차이가 관찰되지 않았다.

⁸예측 대상은 월별 평균 가격(mean_price, 회귀)이며, 손실함수는 제곱오차($h = 1$, Newey–West 추정)를 사용하였다.

sneakers_jordan1($p < 0.001$)과 lego_falcon($p = 0.032$)에서는 Model A가 유의하게 우수하였으며, lego_porsche($p = 0.094$)는 경계 수준에서 Model A가 우세하였다. 반면 sneakers_nb550($p = 0.062$)은 경계 수준에서 Model B가 우세하였다.

RMSE 평균과 DM 등가성의 괴리. 그림 2의 자산별 평균 RMSE는 sneakers에서 Model A(452) vs. Model B(569), lego에서 Model A(176) vs. Model B(199)로 Model A가 일관되게 낮다. cards에서만 양 모형이 사실상 동등하다(334 vs. 329). 이는 DM 검정의 “차이 없음” 판정과 일견 충돌하나, 두 지표는 측정 대상이 다르다. DM 검정은 폴드 합산 시계열 예측 오차의 시점별 부호 차이를 자기상관 보정 후 평가하는 반면, RMSE 평균은 절대 오차의 산술 평균이므로 일부 큰 오차에 강하게 영향받는다. 두 지표의 비대칭성은 §5.4에서 한계로 다룬다.

RQ3 결론(절제된 해석): DM 검정 기준 15개 아이템 중 11개(73%)에서 Model A와 Model B 간 통계적으로 유의한 예측 오차 차이가 관찰되지 않았다. 그러나 자산별 평균 RMSE는 sneakers와 lego에서 Model A가 일관되게 낮으며, Model A가 유의하게 우수한 2개 아이템(jordan1, falcon)이 존재한다. 따라서 본 결과는 “Model B가 Model A보다 우수하다”는 적극적 결론이 아니라, Granger에서 통계적으로 유의한 채널이 표본 외 예측에서는 반드시 유용하지 않다는 점을 보여 준다. 즉 Granger 선별은 다수 아이템에서

표 11: 세 자산쌍의 Jaccard 유사도 $J(S_a, S_b) = |S_a \cap S_b| / |S_a \cup S_b|$. S_a 는 자산 a 의 *SIGNIFICANT* 판정 채널 집합이며, *MARGINAL* 채널은 RQ2의 보수적 판정을 위해 본 집합 정의에서 제외된다(자세한 정의는 §3.7 참조). 본 연구의 임계는 $J < 0.3$ 이면 “자산별 채널 구성이 다름”(RQ2 지지), $0.3 \leq J \leq 0.6$ 이면 “부분적 차이”, $J > 0.6$ 이면 “구성 유사”로 판정한다. sneakers-cards 쌍은 $J = 0.333$ 으로 “부분적 차이” 구간에 속하며 두 자산이 CH1(Google Trends)을 공통 선행 채널로 공유함을 의미한다. sneakers-lego와 cards-lego 쌍은 lego가 *SIGNIFICANT* 채널을 갖지 않아 $J = 0.000$ 으로 산출되며, 이는 “완전한 이질성”으로 해석된다.

자산쌍	비교 집합	J
sneakers – cards	{CH1,CH3,CH4} vs {CH1}	0.333
sneakers – lego	{CH1,CH3,CH4} vs $\emptyset$	0.000
cards – lego	{CH1} vs $\emptyset$	0.000

표 12: 아이템별 Diebold–Mariano(DM) 검정 결과: Model A (전 채널) vs. Model B (Granger 선별 채널). 각 아이টে에 대해 TimeSeriesSplit ($n_{\text{splits}} = 4$, $\text{test_size} = 6$)으로 4개 폴드의 예측 오차를 합산하여 $T = 24$ 개 시점에 대해 DM 검정을 수행하였다. 예측 대상은 월별 평균 가격(mean_price, 회귀)이며, 손실 함수는 제곱오차($h = 1$, Newey–West 추정)이다. DM 통계량이 음(陰)이면 Model A의 오차가 Model B 대비 작음을(Model A 우수), 양(陽)이면 Model B의 오차가 작음을(Model B 우수) 의미한다. 본 연구의 RQ3 판정 기준은 $p < 0.05$ 이고 부호가 Model B에 유리한 경우를 “강한 RQ3 지지”로, $p > 0.10$ 인 경우를 “약한 RQ3 지지(통계적으로 구분되는 손실 없음)”로, $p < 0.05$ 이고 부호가 Model A에 유리한 경우를 “RQ3 비지지”로 보고한다. $0.05 \leq p < 0.10$ 은 “경계 수준”으로 보고한다. 15개 아이টে 중 11개(73%)에서 통계적으로 유의한 차이가 관찰되지 않았으며, sneakers_jordan1($p < 0.001$)과 lego_falcon($p = 0.032$)에서만 Model A가 유의하게 우수하였다. sneakers_nb550($p = 0.062$)은 경계 수준에서 Model B가 우세인 유일한 사례이다.

자산	아이টে	DM 통계량	p	판정
sneakers	sneakers_jordan1	-4.29	< 0.001	Model A 우수
	sneakers_panda	-1.47	0.155	차이 없음
	sneakers_yeezy	-1.09	0.288	차이 없음
	sneakers_travis	0.38	0.705	차이 없음
	sneakers_nb550	1.96	0.062	Model B 우세(경계)
cards	cards_charizard1	1.23	0.230	차이 없음
	cards_charizard2	1.49	0.150	차이 없음
	cards_umbreon	-0.56	0.580	차이 없음
	cards_rayquaza	-0.02	0.985	차이 없음
	cards_pikachu	0.38	0.711	차이 없음
lego	lego_falcon	-2.28	0.032	Model A 우수
	lego_hogwarts	1.27	0.217	차이 없음
	lego_titanic	-0.56	0.579	차이 없음
	lego_porsche	-1.75	0.094	Model A 우세(경계)
	lego_bugatti	0.42	0.677	차이 없음

주. DM 통계량 > 0 이면 Model B의 오차가 작음(B 우수). $p < 0.05$ 유의, $p < 0.10$ 경계.




그림 2: 자산별 RMSE 비교: Model A(전 채널) vs. Model B(Granger 선별 채널). 가로축은 자산군별로 묶인 15개 아이템, 세로축은 `TimeSeriesSplit(n_splits=4, test_size=6)`으로 산출한 4개 폴드 전체의 RMSE(Root Mean Squared Error, 단위: USD)이다. 막대 높이가 낮을수록 예측 오차가 작아 모형의 정확도가 높음을 의미한다. 각 아이템에서 좌측 막대(짙은 색)는 통제 피처(`price_vs_ma3`, `price_chg_lag1~3`)와 CH1~CH5 전 채널을 사용하는 Model A의 RMSE이며, 우측 막대(밝은 색)는 통제 피처와 Granger 유의 또는 경계로 판정된 채널만을 사용하는 Model B의 RMSE이다. 자산별 평균 RMSE를 살펴보면, sneakers는 Model A(452) < Model B(569), lego는 Model A(176) < Model B(199)로 Model A가 일관되게 낮은 반면, cards는 두 모형이 사실상 동등하다(Model A 334 vs. Model B 329). sneakers_jordan1과 lego_falcon에서 Model A와 B의 격차가 가장 크며, 이는 DM 검정(표 12)에서 두 아이템이 Model A 우수로 판정된 결과와 정합된다. 단, DM 검정의 “차이 없음” 판정과 자산 평균 RMSE의 일관된 격차는 동일한 결론을 지시하지 않는다—측정 대상의 차이는 §5.4에서 다룬다.

큰 정보 손실 없이 채널 수를 줄일 수 있지만, 안정적인 예측 변수 선택 규칙으로 일반화하기에는 부족하다. 자세한 한계는 논의 절에서 다룬다.

하이퍼파라미터 튜닝에 대한 견고성 검토

본 절의 주 분석은 고정 하이퍼파라미터 (`n_estimators=100`, `max_depth=3`, `learning_rate=0.05`)를 사용한다. 두 모형 모두 동일 설정을 적용하여 비교 공정성을 유지하였으나, “Model A가 더 큰 피처 공간을 활용하므로 튜닝되지 않은 default에 우연히 더 잘 맞았을 가능성”이 잠재한다. 본 절은 이 가능성을 통제하기 위해 Optuna TPE[Akiba et al., 2019] 기반 60회 베이지안 최적화를 자산별 × 모형별로 독립 수행하여(총 $60 \times 3 \times 3 = 540$ trial), 튜닝된 조건에서 동일 DM 검정을 재실행한다.⁹ 결과는 표 13와 같다.

표 13: Optuna 튜닝 후 자산별 평균 RMSE 및 DM 판정 분포. “기존”은 고정 하이퍼파라미터 결과(표 12), “튜닝”은 자산×모형별 60회 베이지안 최적화 후 결과. B-DH는 §4.5의 DH 검정 결과를 반영한 선별 채널 모형이며, lego는 DH에서 모든 채널이 비유의이므로 통제 피처 4개만을 사용한다(채널 0개). 튜닝 후 절대 RMSE 수치는 크게 감소하지만 세 모형 간 상대적 순위는 유지된다: 모든 자산에서 Model A의 RMSE가 가장 낮으며, sneakers와 lego에서 양의 격차가 일관된다.

자산	A (RMSE)	B-original	B-DH
sneakers	61.14	73.19	76.14
cards	194.04	194.29	194.69
lego	40.45	44.44	43.41

DM 판정 분포 ($n = 15$)		
구분	기존	튜닝 후
차이 없음	11	10
A 우수	2	5
B 경계우세	1	0
A 경계우세	1	0

⁹탐색 공간: `n_estimators` ∈ [50, 300], `max_depth` ∈ [2, 6], `learning_rate` ∈ [0.01, 0.2] (log), `subsample/colsample_bytree` ∈ [0.6, 1.0], `min_child_weight` ∈ [1, 5], `reg_lambda` ∈ [0, 5], `reg_alpha` ∈ [0, 1]. Time-

SeriesSplit($n = 4$, `test_size=6`)으로 자산 내 모든 아이템 평균 RMSE를 최소화. 동일 절차로 Model B-DH(§4.5의 DH 검정 유의 채널 사용)도 추가 비교에 포함하였다.

표 13에서 두 가지 관찰이 도출된다. 첫째, 튜닝은 두 모형의 절대 RMSE를 모두 크게 낮추지만(sneakers Model A: 452 $\rightarrow$ 61, lego Model A: 176 $\rightarrow$ 40), 모형 간 상대 순위는 유지된다. 이는 주 분석의 “Model A 일관 우세” 결론이 단순 default 적합의 부산물이 아님을 시사한다. 둘째, DM 검정에서 “Model A 우수”로 판정되는 아이템은 2개에서 5개로 증가하고(yeezy, charizard1, porsche 추가), “Model B 경계 우세”(nb550)는 사라진다. 즉 튜닝 후에는 Model A 우월성이 약간 더 명확하다. 그럼에도 차이 없음 비율은 67%(10/15)로 여전히 다수이므로, §4.9의 “절제된 결론”은 유지된다.

B-DH 모형은 자산별 평균 RMSE에서 B-original과 유의한 차이가 없다(아이템별 DM 검정: 15개 중 12개 “차이 없음”, 1개 “B-original 우수”, 2개 경계). DH 검정에서 cards에 CH2가 추가되고 lego에서는 채널이 제거되는 변화가 예측 성능에는 거의 반영되지 않는다는 사실은, Granger 선별(통계적 인과성)과 비선형 예측력(SHAP 기여도) 간의 비대칭성을 다시 한 번 시사한다(§5.2 참조). 본 견고성 검토 스크립트는 scripts/tune_xgboost.py에, 결과는 results/xgboost_tuned_params.csv, results/xgboost_tuned_rmse.csv, results/dm_tuned.csv에 보존되어 있다.

SHAP 기반 채널 선별(Model C) 검증

Granger 선별(Model B)이 예측 성능을 개선하지 못한다면, 비선형 예측 기여를 직접 측정하는 SHAP 기반 선별은 다른 결과를 낳는가? 이를 점검하기 위해 각 TimeSeriesSplit($n_{\text{splits}} = 5$) 폴드의 학습 구간에서 Model A(분류기)의 SHAP 중요도를 산출하고, 상위 2개 채널과 통제 피처만으로 **Model C**를 학습하였다. 채널 선택이 폴드별 학습 구간 내부에서만 이루어지므로 선택 단계의 미래 정보 누설이 없으며, 하이퍼파라미터는 §4.9의 자산별 튜닝 값을 양 모형에 동일하게 적용하였다. 평가는 ROC-AUC와 Brier 점수(제곱 확률 오차) 기반 DM 검정으로 수행하였다. 결과는 표 14와 같다.

세 자산 모두에서 Model C는 Model A와 통

표 14: Model A(전 채널) vs. Model C(폴드 내 SHAP 상위 2채널) 분류 성능 비교. AUC는 TimeSeriesSplit($n_{\text{splits}} = 5$) 폴드 평균이며, DM 검정은 Brier 점수(제곱 확률 오차) 기반이다. “주 선택 채널”은 5개 폴드 중 상위 2개로 선택된 빈도를 나타낸다. 세 자산 모두 $|\Delta\text{AUC}| \leq 0.003$, DM $p > 0.50$ 으로 두 모형 간 유의한 차이가 없다.

자산	A	C	DM p	주 선택 채널
sneakers	0.841	0.840	0.678	CH1(5/5)·CH5(4/5)
cards	0.859	0.859	0.504	CH4(4/5)·CH1(3/5)
lego	0.960	0.963	0.646	CH5(4/5)·CH4(3/5)

계적으로 구분되지 않는다(DM $p > 0.50$). 즉 채널 선별 기준을 통계적 선행성(Granger)에서 비선형 예측 기여(SHAP)로 교체하여도 “채널 선별이 예측 성능을 바꾸지 못한다”는 RQ3의 결론은 동일하게 유지되며, 이는 통제 피처(가격 모멘텀)가 예측의 주동력이라는 절제 실험의 해석 (§5.2)과 정합한다. 한편 폴드별 선택 채널은 자산마다 상이하면서도(sneakers CH1·CH5, cards CH4·CH1, lego CH5·CH4) 폴드 간에는 대체로 안정적이어서, 전체 표본 SHAP 순위 (§5.2)와 일관된다. 스크립트는 scripts/run_model_c.py, 결과는 results/model_c_results.csv에 보존되어 있다.

기존 예측 모형과의 벤치마크 비교

본 연구의 자산·채널 구성과 수집 설계는 새로 구축된 것이어서, 동일 조건에서 산출된 선행 연구의 성능 수치와 직접 비교할 수 없다. 이러한 외적 기준선(external baseline)의 부재를 보완하기 위해, 기존 리셀 가격 예측 연구[Raditya et al., 2021]가 사용한 모형군—선형 모형과 랜덤 포레스트—을 본 연구와 동일한 데이터·피처(Model A 구성)·검증(TimeSeriesSplit, $n_{\text{splits}} = 5$)에 적용하여 분류 AUC를 비교하였다. 선형 모형은 본 연구의 분류 설계에 맞추어 엘라스틱 넷 페널티 로지스틱 회귀로 구현하였고, 트리 앙상블 일반의 강건성을 점검하기 위해 CatBoost[Prokhorenkova et al., 2018]를 추가하였다.¹⁰ 결과는 표 15와 같다.

¹⁰XGBoost는 §4.9의 Optuna 튜닝 파라미터를 사용한 반면, CatBoost(트리 200·깊이 4·학습률 0.05), 랜덤 포레스트(트리 200·깊이 4), 엘라스틱넷 로지스틱(l_1 비율 0.5,

표 15: 기준 모형과의 동일 데이터 벤치마크 비교(분류 AUC). 모든 모형은 동일한 피처(통제 피처 + CH1~CH5)와 동일한 검증(TimeSeriesSplit, $n_{\text{splits}} = 5$) 하에서 평가되었다. 선형 기준선과 랜덤 포레스트는 Raditya et al. [2021]의 모형군에 대응한다.

모형	sneakers	cards	lego
엘라스틱넷 로지스틱(선형)	0.601	0.663	0.706
랜덤 포레스트	0.923	0.952	0.937
CatBoost	0.960	0.975	0.956
XGBoost(본 연구)	0.841	0.859	0.960

두 가지 관찰이 도출된다. 첫째, 모든 트리 앙상블(0.84–0.97)이 선형 기준선(0.60–0.71)을 AUC +0.20 이상 상회한다. 동일 피처를 사용하는 선형 분류기가 일관되게 낮은 성능을 보인다는 사실은, 채널·가격 래그와 가격 방향 간 관계가 선형 결합으로는 포착되지 않는 비선형·상호작용 구조임을 시사하며, 본 연구가 트리 기반 모형을 채택한 설계 선택을 사후적으로 정당화한다. 둘째, 트리 모형 간 차이는 자산별로 0.004–0.119 범위로, sneakers와 cards에서는 CatBoost·랜덤 포레스트가 XGBoost보다 높고 lego에서는 XGBoost가 가장 높다. 본 연구의 주 모형 선택은 절대 성능의 극대화가 아니라 해석 도구(SHAP TreeExplainer)의 성숙도와 금융 시계열 문헌에서의 채택 빈도에 근거하므로, 이 차이는 본 연구의 결론에 영향을 주지 않는다. 오히려 어떤 트리 모형에서도 높은 분류 성능이 재현된다는 점은, RQ3에서 관찰된 “채널 구성 변화에 대한 성능 둔감성”이 특정 모형의 산물이 아닐 가능성을 높인다. 단, 본 비교는 Model A 피처 구성에 한정되므로 모형별 채널 선별 효과까지 일반화하지는 않는다. 스크립트는 `scripts/run_model_comparison.py`, 결과는 `results/model_comparison_auc.csv`에 보존되어 있다.

$C = 1$)은 고정 하이퍼파라미터를 사용하였다. 비교 목적이 외적 기준선 제공이므로 모형별 동일 튜닝 예산을 투입하지 않았으며, 따라서 비(非)XGBoost 모형의 수치는 추가 튜닝 시 더 높아질 수 있는 보수적 추정이다.

5 논의

5.1 채널별 선행성의 자산별 분화

Granger 검정 결과는 미디어 채널의 선행적 역할이 자산 유형에 따라 분화될 잠재적 가능성을 시사한다. 스니커즈에서는 Google Trends(CH1), 뉴스 감성(CH3), YouTube 조회수(CH4) 세 채널이 유의 수준에서 선행성을 보였다. CH3의 F 통계량(13.38)이 15회 검정 중 가장 컸으나, 표본 크기와 다중 검정 구조를 고려하면 이를 단정적 인과 증거로 해석하는 데는 신중함이 요구된다. 스니커즈 리셀 시장이 출시 전후 미디어 보도와 셀럽 협업 소식에 민감하게 반응하는 특성을 가진다는 점에서, 본 결과는 해당 자산의 정보 생성 메커니즘과 정합되는 방향으로 읽힐 수 있다.

카드 시장에서는 Google Trends(CH1, $F = 8.42$)가 유의 수준에서 선행하였다. 이는 트레이딩 카드 수요가 커뮤니티 내 검색 관심도와 연동될 가능성을 시사하나, 인과 메커니즘의 확정에는 추가 연구가 필요하다. 레고에서는 CH1이 경계 수준에 그쳐 명확한 선행 채널이 관찰되지 않았으며, 이는 레고 단종 세트의 가격이 미디어 채널보다 재고 수급과 공급 측 정보에 더 강하게 의존할 가능성을 함의한다.

5.2 통계적 선행성과 표본 외 예측 유용성의 괴리

본 연구에서 가장 중요한 방법론적 발견은 Granger 검정의 통계적 유의성이 곧바로 표본 외(out-of-sample) 예측 유용성으로 이어지지 않는다는 점이다. Granger F 순위와 XGBoost SHAP 순위 간에는 체계적 불일치가 관찰된다(표 16). 스니커즈에서 Granger F 1위인 CH3(뉴스 감성)의 평균 $|\text{SHAP}|$ 는 0.011로 채널 5개 중 최하위에 해당하며, Granger 비유의인 CH5(0.124)와 Granger F 3위인 CH1(0.125)이 SHAP 기여도 최상위를 차지한다.

이 불일치는 두 방법의 측정 대상이 근본적으로 다른 데서 기인한다. Granger 검정은 채널 단독으로, 가격의 과거값만 통제된 상태에서 해당 채널이 표본 내 선형 선행성을 갖는지를 평가한

표 16: Model A 분류기에서 산출한 채널별 평균 |SHAP| 값과 Granger 판정의 비교. |SHAP|는 SHAP 값의 절댓값을 의미하며, 행 평균은 해당 채널이 모든 관측에 걸쳐 모형 예측에 미친 평균적 한계 기여도로 해석된다(“전역 변수 중요도”). 동일 행의 “Granger 판정”은 표 5의 결과로, SIG는 SIGNIFICANT, MARGINAL은 MARGINAL, NOT은 NOT_SIG를 의미한다. sneakers에서 Granger F 1위인 CH3는 $|\text{SHAP}| = 0.011$ 로 채널 중 최하위에 해당하며, Granger 비유의인 CH5(0.124)와 CH1(0.125)이 SHAP 상위를 차지하여 선형 인과성과 비선형 예측 기여의 측정 대상이 다름을 직접적으로 드러낸다. cards와 lego에서는 CH4가 SHAP 1위이나 Granger에서는 비유의여서, 채널 단독 Granger 검정이 비선형 신호를 포착하지 못하는 한계를 시사한다. 본 표의 자세한 해석은 §5.2에서 다룬다.

자산		CH1	CH2	CH3	CH4	CH5
sneakers	$ \text{SHAP} $	0.125	0.000	0.011	0.080	0.124
	Granger 판정	SIG	NOT	SIG	SIG	NOT
cards	$ \text{SHAP} $	0.048	0.031	0.025	0.091	0.004
	Granger 판정	SIG	NOT	NOT	NOT	NOT
lego	$ \text{SHAP} $	0.036	0.003	0.000	0.070	0.021
	Granger 판정	MARGINAL	NOT	NOT	NOT	NOT

주. SIG = SIGNIFICANT, MARGINAL = MARGINAL, NOT = NOT_SIG.

다. 반면 SHAP은 모든 변수가 동시에 투입된 비선형 예측 모형에서 채널의 표본 외 한계 기여도를 측정한다. 가격 모멘텀 변수(`price_vs_ma3`, `price_chg_lag1`)가 예측 분산의 대부분을 흡수한 이후에는, Granger에서 선행성을 보인 채널이라 하더라도 XGBoost 내에서 추가로 기여할 분산이 제한적이다. CH3(뉴스 감성)와 같이 선형적 선행성이 강한 채널이 가격 모멘텀과 높은 공분산을 갖는 경우, 가격 라그 변수가 해당 채널의 신호를 미리 포착하여 SHAP 기여도를 잠식한다. 이 패턴은 정보가 가격으로 전이되는 단계 구조로 해석할 수 있다 — 미디어 채널은 가격 변화의 트리거(*trigger*)로 기능하여 Granger 단계에서 선행성을 드러내지만, 일단 추세가 형성된 이후에는 가격 모멘텀이 표본 외 예측의 주 동력이 되어 채널 변수의 한계 기여를 흡수한다(SHAP 단계). 즉 두 지표의 불일치는 방법론적 모순이라기보다 정보 전이 단계의 분업을 반영한다.

이를 보다 직접적으로 검증하기 위해 Granger 유의 채널을 제거한 절제 모형(A-dropGranger)을 구성하였다. cards에서 Granger 유의 채널인 CH1을 제거한 모형이 전채널 모형(Model A) 대비 높은 AUC를 달성하였으며 (0.867 vs. 0.859, DM $p = 0.004$), sneakers에서도 Granger 유의 채널 3개(CH1·CH3·CH4)를 동시에 제거한 모형이 Model A와 유의한 차이를 보이지 않았다

($p = 0.916$). 이는 SHAP 기여도 순위와 Granger F 순위의 불일치를 실험적으로 뒷받침한다.

이 결과는 통계적 인과성(Granger)과 예측적 기여도(SHAP)가 동일한 개념이 아님을 보여준다. 따라서 본 연구의 RQ3 결과는 “Granger 선별이 예측 성능을 개선한다”는 기여라기보다, 리셀 시장에서도 표본 내 유의성과 표본 외 예측력 사이의 괴리가 발생할 수 있음을 보여 주는 탐색적 발견으로 해석하는 것이 타당하다. 이 지점은 본 연구의 한계이면서 동시에 리셀 시장 자료를 이용해 기존 예측 문헌의 경고를 확장해 볼 수 있는 방법론적 시사점이다.

5.3 Model A 우수 예외 아이템 분석

sneakers_jordan1과 lego_falcon에서는 Model A가 통계적으로 유의하게 우수하였다. 두 아이템 모두 해당 자산군의 대표적 플래그십 제품으로, 미디어 채널의 영향이 단일 채널을 초과하는 다층적 구조를 가질 가능성이 있다.

스니커즈 Model B는 Granger 유의 채널인 CH3와 CH4만을 포함하나, SHAP 분석에 따르면 CH1(0.125)과 CH5(0.124)가 채널 기여도 상위를 차지한다. 즉 jordan1의 예측에서 실질적으로 중요한 채널은 Granger로 선별되지 않은 채널이었으며, 이로 인해 Model B가 정보 손실을 겪었다.

lego_falcon의 경우 레고 Model B는 CH1 만




그림 3: 자산별 XGBoost 피쳐 중요도 및 SHAP Summary Plot (Model A, 분류 기준). 각 행은 자산군 한 곳에 대응하며, 위부터 차례로 스니커즈, 카드, 레고 이다. 각 행은 두 패널로 구성된다 — 왼쪽 패널은 XGBoost의 *Gain* 기반 피쳐 중요도로, 각 변수가 트리 분기점으로 선택될 때 발생시킨 손실 함수 감소량의 누적값에 비례한다(클수록 모형 내 중요도가 큼). 오른쪽 패널은 SHAP Summary Plot으로, 점 하나가 하나의 관측 월(아이템-월)을 나타내며, 점의 가로 좌표는 해당 관측에 대한 변수의 SHAP 값(예측 logit에의 기여 부호와 크기), 점의 색은 해당 관측에서의 변수값 자체(붉을수록 높은 값, 푸를수록 낮은 값)를 표현한다. 변수는 평균 |SHAP| 내림차순으로 정렬되어 있으며, 통제 피쳐(*price_vs_ma3*, *price_chg_lag1* ~3)가 모든 자산에서 상위를 차지한다. 채널 변수만을 보면, sneakers는 CH1·CH5가 채널 중 상위 두 자리를 점유하고 Granger F 1위였던 CH3는 채널 최하위로 떨어진다. cards는 CH4가 채널 1위, CH1이 2위이며, lego도 CH4가 채널 1위, CH1이 2위로 cards와 유사한 구조이다. 이 결과는 표 16의 수치적 정리와 일관되며, 선형 인과성(Granger)과 비선형 예측 기여(SHAP)의 측정 대상이 근본적으로 다름을 시각적으로 보여 준다 (§5.2 참조).




그림 4: 절제 실험(Ablation Study): 9개 채널 구성 모형의 자산별 AUC 비교. 각 막대는 TimeSeriesSplit($k = 5$) 교차검증 평균 AUC를 나타낸다. Model A(파랑, 점선 참조선)는 가격 래그 4개와 채널 5개 전부를 사용하는 기준 모형이며, Channels-only(회색, X 표시)는 가격 래그 없이 채널만 사용할 경우로 AUC가 0.47-0.53에 불과하여 가격 래그가 예측의 핵심임을 확인한다. A-dropGranger(빨강)는 Granger 유의 채널을 제거한 절제 모형으로, cards에서 Model A 대비 높은 AUC를 달성하였으며(★, DM $p = 0.004$), sneakers에서는 유의한 차이가 없었다($p = 0.916$). 채널 하나만 포함한 CH-only 모형들도 Model A와 통계적으로 동등하거나 우세하여, 소표본($N=48$) 환경에서 다채널 결합이 오히려 노이즈로 작용할 수 있음을 시사한다.

을 포함하지만, SHAP 분석에서 CH4(0.070)가 CH1(0.036)보다 높은 기여도를 보인다. Millennium Falcon은 Star Wars 관련 이벤트와 연동된 YouTube 콘텐츠 급증이 주기적으로 발생하는 아이템으로, 채널 단독 Granger 검정이 CH4의 복잡한 비선형 기여를 포착하지 못한 결과로 해석된다.

두 사례는 Granger 선별이 특정 아이템에서는 최적 채널 집합을 과소 포함할 수 있음을 보여 주며, 이를 한계로 명시한다.

5.4 한계

본 연구의 한계는 다음과 같다.

소표본 및 다중 검정의 검정력 제약. 자산당 48개월의 관측치는 Granger 검정과 XGBoost 교차검증 모두에서 통계적 검정력을 제약한다. 래그 1-4 범위에서 BIC로 래그를 선택하더라도 유효 관측치는 44-47개로 감소하며, 동일 자산에 대해 5개 채널을 순차적으로 검정하므로 자유도 압박과 다중 비교 문제가 누적된다. 본 연구가 결과를 탐색적 발견으로 명시하고 BH 보정 결과를 부록에 함께 제시하는 것은 이러한 구조

적 한계를 보완하기 위함이며, 본 결과를 확증적(confirmatory) 증거로 일반화하기 위해서는 더 긴 패널과 사전 등록 설계가 요구된다.

ADF 정상성의 한계. sneakers의 score_ch1은 1차 차분 후에도 ADF $p = 0.120$ 으로 단위근을 엄밀히 기각하지 못한다(표 4 각주 †). 실질적 자기상관 감소를 근거로 차분값을 Granger 검정에 투입하였으나, 비정상 잔차가 잔존할 경우 sneakers CH1 ($p = 0.041$)의 SIGNIFICANT 판정이 약화될 수 있다. 본 채널은 BH 보정 시에도 NOT_SIG로 탈락한다는 점에서 견고성이 가장 약한 발견이며, 후속 연구에서 KPSS 추가 검토와 더 긴 패널을 통한 재현이 필요하다.

분석 단위 불일치(자산 수준 Granger vs. 아이템 수준 XGBoost). RQ1·RQ2의 Granger 검정은 아이템 5개의 월별 평균을 사용한 자산-월 단위 대표 시계열에서 수행되며, RQ3의 XGBoost/DM은 15개 아이템-월 단위에서 수행된다. Model B의 채널 구성은 자산 수준 Granger 결과를 동일 자산군의 모든 아이템에 일률적으로 적용하므로, 개별 아이템 수준에서는 다른 채널이 더 적합할 수 있다(예: lego_falcon에서 SHAP CH4가 CH1보다 큼; §5.3). 자산 수

준 평균은 아이템 간 잡음 감쇄 효과가 있으나, 단위 적합성 측면에서는 패널 VAR[Holtz-Eakin et al., 1988]이나 이질적 패널 Granger 검정[Dumitrescu and Hurlin, 2012] 또는 아이템별 단독 Granger 설계가 더 엄밀하다. 본 연구는 §4.5에서 DH 패널 Granger를, §4.6에서 다변수 VAR 블록·개별 인과 검정을 보충 적용하여 이 한계를 부분적으로 해소하였으며, BH 보정 후 세 검정 모두에서 일관 유의한 채널이 cards-CH1로 집약됨을 확인하였다. 추가로 §4.6의 다변수 VAR 블록·개별 검정은 채널 간 다중공선성을 통제한 후에도 cards-CH1과 sneakers-CH3가 BH 보정을 통과함을 보여, 세 검정의 교집합 발견(cards-CH1)을 자산-공통의 가장 견고한 미디어 선행 채널로 확립한다(표 10). 그러나 본 검정은 $N = 5$ 로 정규 근사가 비교적 약하고 표준 점근 근사만을 사용하였으므로, 잔차 부트스트랩 변형의 적용은 후속 과제로 남는다.

CH3 대리변수. 뉴스 감성(CH3)은 News-API+FinBERT를 원설계로 하였으나, 무료 플랜의 역사 자료 30일 제한으로 GDELT timelinetone으로 대체하였다. GDELT 톤은 도메인 특화 학습 없이 자동 산출되는 일반 감성 점수로, 리셀 특화 어휘·맥락에 대한 감도가 낮을 수 있다.

sneakers_yeezy 결측. StockX 거래량 표본 추출 아티팩트로 4개월 결측이 발생하여 선형 보간으로 처리하였다. 보간 구간의 가격 변동이 비선형이었을 경우 분석 결과에 편의를 유발할 수 있다.

lego_porsche·bugatti Google Trends 0 값. 해당 아이템의 CH1 점수에는 각각 21/48, 25/48개월의 0값이 포함되어, 채널 신호의 정보량이 제한된다. 이는 CH1 관련 분석에서 과소 추정 편의를 유발할 수 있으며, 결과 해석 시 유의해야 한다.

z-score 전역 적합. 채널 점수의 z-score는 전체 샘플로 추정하였다. 엄밀한 시계열 교차검증에서는 각 학습 폴드의 통계량만을 사용해야 하나, 소표본 특성상 폴드별 추정 분산이 커 전역 적합을 채택하였다. 이는 미미한 수준의 정보 누설 가능성을 내포한다.

다중 검정 보정과 통계적 검정력의 trade-off. 본 연구는 raw p -값을 1차 판정 지표로 사용하고 BH 보정 결과를 부록 §A에 병기하였다(표 18). BH 보정 후에는 sneakers CH3와 cards CH1 두 조합만 유의성을 유지하나, 이는 채널 효과의 실재성이 약해서라기보다 $N = 48$ 의 짧은 패널이 가지는 표본 검정력(statistical power)의 한계로 인해 제2종 오류(Type II Error)가 증가한 결과일 가능성도 배제하기 어렵다. 따라서 본 연구의 BH 보정 결과는 보수적 하한(*conservative lower bound*)으로 해석되어야 하며, T 를 60개월 이상으로 확장한 후속 연구가 본 결과의 견고성을 재검증할 필요가 있다. Granger 유의 채널이 표본 외 예측 성능 개선으로 직접 이어지지 않는다는 본 연구의 방법론적 발견에 대한 상세 논의는 §5.2을 참조하라.

DM 검정의 태스크 불일치. 메인 XGBoost는 가격 방향성(0/1, 분류)을 예측하나, DM 검정은 평균 가격 수준(회귀, RMSE 기반)의 예측 오차를 비교한다. 두 태스크의 목적이 상이하므로 DM 결과를 분류 성능의 직접 증거로 해석하는 데는 한계가 있다. 마찬가지로 표 16의 SHAP 분석은 분류 모형에서 산출하므로, 표 12의 회귀 기반 DM 결과와 같은 적합 모형이 아니다. 두 결과는 동일 피처 집합 하 보완 지표로 제시되며, 단일 모형 기반 일관 비교가 아님을 명시한다.

RMSE 평균과 DM 등가성의 괴리. §4.9에서 보고하였듯, 자산별 평균 RMSE는 sneakers·lego에서 Model A가 일관되게 낮음에도 DM 검정은 “차이 없음”으로 판정한 아이템이 대다수이다. 이는 DM이 시점별 오차 차이의 표본 평균을 자기상관 보정 표준오차로 검정하므로 일부 큰 오차의 영향이 평균화되기 때문이다. 따라서 “DM에서 유의한 차이가 없다”와 “선별 채널이 우수하다”는 동치가 아니며, 실무적 권고는 평균 RMSE와 DM을 함께 보고하는 것이다. SPA(superior predictive ability; Hansen, 2005) 또는 MCS(model confidence set; Hansen et al., 2011)와 같은 다중 모형 비교 절차를 적용한 후속 검증이 권장된다. 또한 추정 매개변수 불확실성을 반영한 West [1996]의 예측 능력 추론은 DM의 보완 도구로 활용 가능하다.

탐색적 연구 특성. 본 연구는 리셀 시장에서의 미디어 채널 선행성을 처음으로 다중 자산·다중 채널 설계로 탐색하는 성격을 갖는다. 다중비교 보정 (Benjamini-Hochberg FDR) 적용 시 sneakers CH1과 CH4가 자산-평균 유의 채널에서 탈락하여 유의 채널은 2개(sneakers CH3, cards CH1)로 줄어든다. §4.5의 DH 패널 검정에 동일 BH 보정을 적용하면 *sneakers CH4*, *cards CH1*이 유지되어, 두 검정에서 BH 보정 후 일관되게 살아남는 발견은 **cards-CH1** 한 조합으로 좁혀진다. BH 보정 전후 결과 비교는 부록 표 18에 제시한다.

직접 선행 연구의 부재. 본 연구는 리셀 시장 가격 결정에 미디어 채널 선행성을 다중 자산·다중 채널 설계로 비교한 거의 첫 시도로 보이며 (§2 참조), 이는 강점인 동시에 한계이다. 동일 정의·동일 기간에서 결과를 직접 비교 가능한 기준선(*benchmark*) 연구가 부재하여, 본 연구의 효과 크기(예: sneakers CH3 $F = 13.38$)가 리셀 시장 표준 분포 내 어느 위치에 있는지 평가할 수 없다. 본 발견은 향후 동일 설계의 반복 연구에서 견고성을 검증하는 출발점으로 활용될 필요가 있다.

측정 범위의 한계 — 폐쇄형 SNS의 부재. 본 연구의 다섯 채널은 공개 무료 API 또는 공개 웹 자료를 통해 일관되게 수집 가능한 채널로 한정되었다. 따라서 Instagram·TikTok·Discord·Reddit 비공개 서브레딧과 같이 폐쇄형 또는 비공개 API를 기반으로 하는 SNS는 분석에서 제외되었다. 이는 두 가지 측면에서 결과 해석에 영향을 미칠 수 있다. 첫째, 스니커즈·트레이딩 카드 커뮤니티의 상당 부분은 Discord 서버나 Instagram 마이크로 커뮤니티에서 정보 교환이 이루어지므로, 본 연구가 측정하지 못한 잠재적 선행 신호가 존재할 가능성이 높다. 특히 TikTok의 짧은 영상 콘텐츠는 Z세대 수집가층의 정보 노출에 결정적 역할을 하나, 공개 API가 제한적 이어서 시계열 수집이 어렵다. 둘째, 본 연구가 측정한 다섯 채널 중 일부(예: YouTube 조회수)가 통계적 선행성을 보였더라도, 이는 측정 가능한 채널 군 안에서의 상대적 효과이며, 폐쇄형 채널까지 포함한 진정한 정보 환경을 반영하

지는 못한다. 후속 연구는 (i) TikTok·Instagram Graph API의 공식 연구자 프로그램 신청, (ii) 사용자 동의 기반 Discord 데이터 수집, (iii) Reddit Pushshift 아카이브 활용 등을 통해 채널 범위를 확장할 것을 권장한다.

5.5 이론적 함의 — 자산별 채널 분화의 경제학적 해석

본 연구의 핵심 발견 — 미디어 채널의 가격 선행성이 자산 유형별로 분화된다는 점 — 은 단순한 통계적 패턴 이상의 함의를 가지며, 정보경제학과 행동재무학의 기존 이론적 프레임으로 해석될 수 있다. 본 절은 세 자산군에서 관찰된 이질적 채널 구성을 가격 형성의 정보 메커니즘 차이로 환원하여 설명한다.

스니커즈 — 정보 비대칭 해소 채널로서의 뉴스 감성. 스니커즈에서 CH3(뉴스 감성)가 가장 강한 선행 효과($F = 13.38$)를 보인 점은, 이 시장의 가격 결정이 출시 전후의 미디어 보도와 셀럽 협업 소식에 강하게 의존한다는 점과 정합된다. 한정판 협업 출시 정보, 가품 적발, 셀럽 착용 사례 등은 Tetlock [2007]이 분석한 미디어 매개 정보 비대칭 해소 메커니즘과 동일 구조를 가진다. 즉 보도의 양이 아닌 방향(부정/긍정 어조)이 가격 충격을 일으키며, 이는 Tetlock et al. [2008]이 보고한 “기업 펀더멘털 대비 부정 어휘의 추가 정보”와 정성적으로 부합한다. 다만 본 결과는 DH 검정과 표본 외 예측 검증에서 약화되므로, 스니커즈 시장의 가격 형성에서 미디어 보도가 인과적 기제(*causal channel*)로 작동한다고 단정하기보다는 후속 식별 연구가 검증해야 할 가설로 해석하는 것이 적절하다. 이는 Engelberg and Parsons [2011]의 외생적 식별 전략을 리셀 시장으로 확장한 후속 연구로 발전 가능하다.

트레이딩 카드 — 표준화된 등급제 하의 수요 신호. 카드 시장에서 CH1(Google Trends)이 유일한 유의 채널인 점은, 본 시장의 정보 비대칭 수준이 상대적으로 낮다는 구조적 특성에 기인한다고 해석할 수 있다. PSA 그레이딩은 카드의 품질 정보를 표준화함으로써 “레몬 시장(*market for lemons*)” 문제를 부분적으로 해소하므로, 신규 정보 충격이 상대적으로 드물고 가격은 잠

재 수요의 변동에 더 직접적으로 반응 한다. Da et al. [2011]의 검색 기반 관심 지표가 개별 자산의 수요 측 압력을 측정한다는 직관과 일관되게, 카드 시장의 가격은 “뉴스보다 검색에 반응” 한다는 패턴이 관찰된다. 이는 Joseph et al. [2011]이 보고한 “검색 기반 비정상 수익률 예측” 메커니즘과도 정합된다.

레고 — 단종 후 공급 측 희소성의 우위. 레고에서 어떤 미디어 채널도 명확한 선행 효과를 보이지 않은 점은 (CH1만 경계 수준), 본 시장이 공급 측 충격에 강하게 의존한다는 사실을 시사한다. 단종된 레고 세트는 추가 생산이 불가능하므로 가격 형성의 핵심 변동 요인은 잔존 재고와 거래 빈도이며, 이는 Dobrynskaya and Kishilova [2022]이 보고한 “LEGO 가격의 단종 후 평균 연 11% 수익률”의 주된 메커니즘으로 알려져 있다. 즉 레고에서는 미디어 채널이 수요 신호로서 작동하더라도 공급 측 비탄력성 때문에 가격에 매개되지 않는 셈이다. 본 해석은 Burton and Jacobsen [1999]의 수집품 시장 분석에서 “공급의 본질적 비탄력성”이 가격 변동성의 주된 동인이라는 결론과 부합한다.

종합 — “정보 비대칭 강도 × 공급 탄력성” 2×2 프레임. 세 자산군의 채널 분화는 다음 두 차원의 결합으로 단순화될 수 있다. (i) 정보 비대칭 수준: 스니커즈 高 vs. 카드 低 vs. 레고 中. (ii) 공급 탄력성: 스니커즈 中(재출시 가능) vs. 카드 低(고정 발행량) vs. 레고 極低(단종). 정보 비대칭이 높을수록 뉴스·감성 채널이 우월하며(스니커즈 CH3), 비대칭이 낮으면 수요 신호인 검색 트렌드가 우월하다(카드 CH1). 공급 탄력성이 극단적으로 낮은 시장(레고)에서는 미디어 신호 자체가 가격에 매개되지 못한다. 본 가설은 본 연구의 표본 한계 ($N = 48, 3$ 자산군)에서 탐색적 해석으로 제시되며, 후속 연구의 확증적 검증 대상이다.

5.6 4개 태스크 통합 정리

본 연구는 채널의 선행성과 예측 기여를 네 가지 서로 다른 태스크로 평가하였다. 각 태스크가 동일 채널에 대해 일관된 신호를 주는지를 표 17에 정리한다. 태스크 간 측정 대상이 다르므로

완전한 일치를 기대하기보다는, 한 채널이 다수 태스크에서 일관되게 양의 신호를 보일 때 해당 채널을 실용적으로 유용한 선행 지표로 판단하는 것이 적절하다.

표 17에서 가장 견고한 선행 지표 후보는 cards의 CH1이다. cards-CH1은 단독 Granger, DH 패널 검정, VAR 개별 검정에서 모두 BH 보정 후 유의성을 유지하고, Model B에도 포함되며 SHAP 순위에서도 상위권에 위치한다. sneakers의 CH1은 Granger 유의와 SHAP 1위를 동시에 보이지만, ADF 정상성 및 BH 보정 이후의 견고성이 약하므로 cards-CH1과 같은 수준의 핵심 발견으로 두기는 어렵다. 반면 sneakers의 CH3(뉴스 감성)는 Granger에서는 최고 F 를 보였으나 SHAP에서는 채널 중 최하위로 나타나, 선형 인과성과 비선형 예측 기여 간 측정 대상 차이가 가장 두드러진 사례이다.

6 결론

본 연구는 스니커즈·트레이딩 카드·레고 리셀 시장에서 다섯 가지 미디어 채널—Google Trends, 뉴스 보도량, 뉴스 감성, YouTube 조회 수, YouTube 댓글 감성—의 가격 선행성을 2022년 1월부터 2025년 12월까지 48개월 월별 패널로 실증하였다.

RQ1 / H1. 15회 단독 Granger 검정 중 4회가 유의, 1회가 경계 수준으로, 채널의 선행적 역할이 일부 자산-채널 조합에서 잠정적으로 관찰되었다. 선행 강도는 스니커즈의 뉴스 감성($F = 13.38$)에서 가장 두드러졌으며, 카드의 Google Trends($F = 8.42$)가 뒤를 이었다. 단, 다중 검정 보정(BH FDR) 적용 시 유의 채널은 2개로 축소되므로, 이는 확증적 선행성 증거라기보다 후속 연구에서 검증할 가설로 받아들이는 것이 적절하다. 따라서 **H1은 잠정적으로 지지**되되, BH 보정 기준에서는 부분 지지로 해석된다. 보충 분석인 직교화 충격반응함수(§4.7)는 두 BH-견고 채널 모두 1~2개월 선행 + 4개월 내 감쇄의 단기 충격 구조를 보이되 부호가 정반대(cards-CH1 양, sneakers-CH3 음)임을 추가로 드러낸다. 더불어 자산-평균 검정과 RQ3

표 17: 채널 × 자산 조합에 대한 4개 태스크 통합 비교. 본 표는 본 연구의 네 가지 핵심 분석—(i) 단독 Granger 검정 (§4.3), (ii) Model B 채널 포함 여부 (§3.8), (iii) Model A 분류기 SHAP 상위 순위 (§5.2), (iv) Diebold–Mariano 검정의 모형 간 우열 (§4.9)—결과를 채널 단위로 한 표에 정렬한 것이다. DM 열은 채널별이 아닌 모형 단위 결과이므로 같은 자산 내 행에서는 동일 결론(“차이 없음 또는 A 우세” 등)을 공유 한다. 본 표의 목적은 어느 채널이 다수 태스크에서 일관되게 양의 신호를 보였는지를 한눈에 확인하는 데 있다. 가장 견고한 조합은 세 인과 검정에서 BH 보정 후에도 일관되게 살아남은 cards-CH1이며, sneakers CH1은 Granger와 SHAP에서 모두 양의 신호를 보이지만 ADF·BH 보정과 DH 검정에서 약화되므로 보조적 탐색 후보로만 해석한다. sneakers의 CH3는 Granger F 최대($F = 13.38$)임에도 SHAP에서는 최하위로 나타나, 선형 인과성과 비선형 예측 기여의 측정 대상 차이가 가장 두드러진 사례 이다.

자산	채널	Granger	Model B	SHAP 순위	DM 판정
sneakers	CH1 GT	SIG	O	1위	차이 없음 또는 A 우세
	CH2 뉴스량	NOT	X	5위	
	CH3 뉴스감성	SIG	O	4위	
	CH4 YT조회수	SIG	O	3위	
	CH5 댓글감성	NOT	X	2위	
cards	CH1 GT	SIG	O	2위	차이 없음
	CH2 뉴스량	NOT	X	3위	
	CH3 뉴스감성	NOT	X	4위	
	CH4 YT조회수	NOT	X	1위	
	CH5 댓글감성	NOT	X	5위	
lego	CH1 GT	MARGINAL	O	2위	차이 없음 또는 A 우세
	CH2 뉴스량	NOT	X	4위	
	CH3 뉴스감성	NOT	X	5위	
	CH4 YT조회수	NOT	X	1위	
	CH5 댓글감성	NOT	X	3위	

머신러닝 단계의 분석 단위 불일치를 보완하기 위해 적용한 Dumitrescu and Hurlin [2012]의 패널 Granger 검정 (§4.5)은 BH 보정 후에도 자산-평균과 DH 양쪽에서 일관되게 유의한 채널이 cards-CH1 한 조합으로 집약됨을 보였으며, 자산-평균에서 가장 강했던 sneakers-CH3가 어떤 개별 아이템에서도 인과성을 보이지 않아 평균 과정에서 인공적으로 증폭되었을 가능성이 있음을 시사한다. 채널 간 다중공선성을 통제한 §4.6의 다변수 VAR 블록·개별 검정에서도 단독·DH·VAR 세 검정 모두에서 BH 보정 후 일관되게 유의한 발견은 cards-CH1이 유일하며, 본 연구는 이를 가장 견고한 자산-공통 미디어 선행 채널로 보고한다.

RQ2 / H2. 자산쌍 간 Jaccard 유사도는 sneakers-cards = 0.333, 그 외 = 0.000으로, 자산 유형 간 유의 채널 구성이 대체로 상이함이 관찰되었다. 스니커즈는 뉴스 생태계와 검색 트렌드(CH1·CH3·CH4), 카드는 검색 관심도(CH1), 레고는 유의 채널 미확인이라는 분포는 자산 특성에 따른 정보 처리 경로의 이질성에 부합한다.

다만 sneakers와 cards가 CH1을 공통으로 가지므로, 검색 트렌드는 자산 간 공통 선행 신호일 가능성이 잠정적으로 시사된다. 모든 자산쌍에서 $J < 0.6$ 이 확인되어 **H2**는 지지된다.

RQ3 / H3. 아이템 15개 중 11개(73%)에서 Granger 선별 채널 모형(Model B)과 전채널 모형(Model A) 간 통계적으로 유의한 DM 예측 오차 차이가 관찰되지 않았다. 그러나 자산별 평균 RMSE는 sneakers·lego에서 Model A가 일관되게 낮고, sneakers_jordan1과 lego_falcon 2개 아이템에서는 Model A가 유의하게 우수하여 “Model B가 Model A보다 우수하다”는 적극적 결론은 성립하지 않는다. 절제 실험에서도 Granger 유의 채널을 제거한 모형이 일부 자산에서 AUC 손실을 보이지 않아, Granger 유의성이 표본 외 예측 유용성을 보장하지 않음이 확인된다. 선별 기준을 SHAP 중요도로 교체한 Model C 역시 세 자산 모두에서 Model A와 유의한 차이를 보이지 않아(DM $p > 0.50$, §4.9), 이 결론은 채널 선별 기준의 선택과 무관하게 유지된다. 따라서 **H3**는 약하게만 지지되며, Granger

선별은 다수 아이템에서 큰 손해 없이 채널 수를 줄일 수는 있으나 안정적인 예측 변수 선택 규칙으로 보기는 어렵다. 본 결과는 리셀 시장에서도 통계적 선행성과 예측 유용성이 분리될 수 있음을 보여 주는 탐색적 발견으로 해석된다. 한편 동일 데이터에 기존 리셀 예측 연구의 모형군을 적용한 벤치마크 비교 (§4.9)에서는 트리 앙상블이 선형 기준선을 AUC +0.20 이상 상회하여, 비선형 모형 채택의 타당성과 본 결론의 모형 비의존성을 확인하였다. 자산-아이템 단위 불일치 (§5.4)와 SPA/MCS 절차를 통한 후속 검증이 필요하다.

핵심 발견의 성격 구분. 본 연구의 핵심 발견은 두 가지로 구성되며 성격이 상이하다. (i) 실증적 발견: 단독 Granger, DH 패널, 다변수 VAR 세 인과 검정에서 BH 보정 후에도 일관 생존한 유일한 자산-공통 채널은 **cards-CH1(Google Trends)**이며, IRF에서도 +10.80의 양의 가격 반응이 95% 신뢰구간에서 0을 배제한다. 이는 본 연구가 제시하는 유일한 자산-공통 선행 지표 후보이다. (ii) 방법론적 발견: Granger 검정의 표본 내 유의성은 XGBoost의 표본 외 예측 유용성으로 곧바로 전환되지 않으며(통계적 선행성과 예측 유용성의 괴리), Granger 유의 채널을 제거한 절제 모형이 cards에서 오히려 유의하게 높은 AUC를 달성한 점이 이를 직접적으로 뒷받침한다. 두 발견은 각각 RQ1·RQ2 및 RQ3에 대한 답으로, 전자는 탐색적 실증 후보로, 후자는 리셀 시장 자료를 통해 기존 예측 문헌의 in-sample $\neq$ out-of-sample 경고[Welch and Goyal, 2008]를 새 도메인으로 확장한 방법론적 시사점으로 보고한다.

시사점. 본 연구의 탐색적 발견은 세 집단에 상이한 실무적 함의를 제공한다.

리셀 투자자 및 수집가. 가장 견고한 실무 후보는 트레이딩 카드의 Google Trends(CH1)이다. cards-CH1은 여러 검정에서 일관되게 유지되어, 카드 시장에서는 검색 관심도를 1-2개월 선행 수요 지표로 참고할 수 있다. 스니커즈의 검색·뉴스·YouTube 신호는 탐색적 후보로 남지만, BH 보정과 표본 외 예측 검증에서 약화되므로 기계적 매매 신호로 해석해서는 안 된다. 모든

채널 신호는 거래량, 재고, 출시·재출시 정보와 함께 종합 판단하는 보조 지표로 활용하는 것이 적절하다.

리셀 플랫폼 운영자. 가격 이상 탐지 및 수요 예측 모형에 채널 신호를 통합할 때, 자산 유형별로 유효 채널이 다름을 반영한 자산별 맞춤형 피쳐 집합이 권장된다. 다만 Granger 유의 채널을 곧바로 예측 피쳐로 채택하기보다, 각 채널을 표본 외 검증과 절제 실험으로 다시 걸러야 한다. 전채널을 일괄 사용하는 것보다 선별 채널 중심으로 모형을 구성하면 파이프라인 유지 비용을 줄일 수 있지만, 본 연구의 결과는 그 과정에서 예측력 손실 여부를 별도로 검증해야 함을 보여 준다.

학술 연구자. 본 연구에서 활용한 “공개 무료 데이터(Google Trends, GDELT, YouTube API) → Granger 선별 → XGBoost + SHAP + DM” 파이프라인은 데이터 수집 비용이 낮아 다른 리셀 자산군(명품·시계·예술품 등)으로 확장 적용이 용이하다. 이 파이프라인 자체가 탐색적 비교 연구의 재현 가능한 설계 틀로 기여할 수 있다.

향후 연구. (i) 더 긴 패널(5년 이상)과 아이টে 수 확대를 통해 N 차원과 T 차원 모두에서 DH 검정의 통계적 검정력을 강화할 것, (ii) CH3를 도메인 특화 FinBERT로 대체하여 감성 신호의 품질을 개선할 것, (iii) 본 연구에서 $N = 5$ 로 정규 근사가 비교적 약한 DH 검정에 대해 잔차 부트스트랩 변형[Dumitrescu and Hurlin, 2012]을 적용하여 추론의 견고성을 높일 것, (iv) DM 단일 비교의 한계를 보완하기 위해 SPA[Hansen, 2005] 또는 MCS[Hansen et al., 2011] 등 다중 모형 비교 절차를 적용할 것, (v) 탐색적 성격의 본 연구를 토대로 사전 등록 설계(pre-registration)를 통한 확증 연구로 발전시킬 것을 제안한다.

참고 문헌

Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta, and Masanori Koyama. Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International*

- Conference on Knowledge Discovery and Data Mining (KDD '19)*, pages 2623–2631. ACM, 2019.
- Werner Antweiler and Murray Z. Frank. Is all that talk just noise? the information content of internet stock message boards. *Journal of Finance*, 59(3):1259–1294, 2004.
- Dogu Araci. FinBERT: Financial sentiment analysis with pre-trained language models, 2019. arXiv:1908.10063.
- Yoav Benjamini and Yosef Hochberg. Controlling the false discovery rate: A practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society. Series B*, 57(1):289–300, 1995.
- Johan Bollen, Huina Mao, and Xiaojun Zeng. Twitter mood predicts the stock market. *Journal of Computational Science*, 2(1):1–8, 2011.
- Ilaria Bordino, Stefano Battiston, Guido Caldarelli, Matthieu Cristelli, Antti Ukkonen, and Ingmar Weber. Web search queries can predict stock market volumes. *PLoS One*, 7(7):e40014, 2012.
- Benjamin J. Burton and Joyce P. Jacobsen. Measuring returns on investments in collectibles. *Journal of Economic Perspectives*, 13(4):193–212, 1999.
- Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.
- Chester Curme, Tobias Preis, H. Eugene Stanley, and Helen Susannah Moat. Quantifying the semantics of search behavior before stock market moves. *Proceedings of the National Academy of Sciences*, 111(32):11600–11605, 2014.
- Zhi Da, Joseph Engelberg, and Pengjie Gao. In search of attention. *Journal of Finance*, 66(5):1461–1499, 2011.
- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL-HLT 2019*, pages 4171–4186, 2019.
- David A. Dickey and Wayne A. Fuller. Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, 74(366):427–431, 1979.
- Francis X. Diebold and Roberto S. Mariano. Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3):253–263, 1995.
- Elroy Dimson, Peter L. Rousseau, and Christophe Spaenjers. The price of wine. *Journal of Financial Economics*, 118(2):431–449, 2015.
- Victoria Dobrynskaya and Julia Kishilova. LEGO: The toy of smart investors. *Research in International Business and Finance*, 59: 101539, 2022.
- Elena-Ivona Dumitrescu and Christophe Hurlin. Testing for Granger non-causality in heterogeneous panels. *Economic Modelling*, 29(4):1450–1460, 2012.
- Joseph E. Engelberg and Christopher A. Parsons. The causal impact of media in financial markets. *Journal of Finance*, 66(1):67–97, 2011.
- Diego García. Sentiment during recessions. *Journal of Finance*, 68(3):1267–1300, 2013.
- C. W. J. Granger. Investigating causal relations by econometric models and cross-spectral methods. *Econometrica*, 37(3):424–438, 1969.

- Shihao Gu, Bryan Kelly, and Dacheng Xiu. Empirical asset pricing via machine learning. *Review of Financial Studies*, 33(5):2223–2273, 2020.
- Peter R. Hansen, Asger Lunde, and James M. Nason. The model confidence set. *Econometrica*, 79(2):453–497, 2011.
- Peter Reinhard Hansen. A test for superior predictive ability. *Journal of Business & Economic Statistics*, 23(4):365–380, 2005.
- Steven L. Heston and Nitish Ranjan Sinha. News vs. sentiment: Predicting stock returns from news stories. *Financial Analysts Journal*, 73(3):67–83, 2017.
- Douglas Holtz-Eakin, Whitney Newey, and Harvey S. Rosen. Estimating vector autoregressions with panel data. *Econometrica*, 56(6):1371–1395, 1988.
- Kissan Joseph, M. Babajide Wintoki, and Zelin Zhang. Forecasting abnormal stock returns and trading volume using investor sentiment: Evidence from online search. *International Journal of Forecasting*, 27(4):1116–1127, 2011.
- Colm Kearney and Sha Liu. Textual sentiment in finance: A survey of methods and models. *International Review of Financial Analysis*, 33:171–185, 2014.
- Kalev Leetaru and Philip A. Schrodt. GDELT: Global data on events, location and tone, 1979–2012. ISA Annual Convention, 2013.
- Tim Loughran and Bill McDonald. When is a liability not a liability? textual analysis, dictionaries, and 10-ks. *Journal of Finance*, 66(1):35–65, 2011.
- Tim Loughran and Bill McDonald. Textual analysis in accounting and finance: A survey. *Journal of Accounting Research*, 54(4):1187–1230, 2016.
- Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems 30 (NeurIPS)*, pages 4765–4774, 2017.
- Helmut Lütkepohl. *New Introduction to Multiple Time Series Analysis*. Springer, Berlin, 2005.
- Jianping Mei and Michael Moses. Art as an investment and the underperformance of masterpieces. *American Economic Review*, 92(5):1656–1668, 2002.
- Helen Susannah Moat, Chester Curme, Adam Avakian, Dror Y. Kenett, H. Eugene Stanley, and Tobias Preis. Quantifying Wikipedia usage patterns before stock market moves. *Scientific Reports*, 3:1801, 2013.
- Tobias Preis, Helen Susannah Moat, and H. Eugene Stanley. Quantifying trading behavior in financial markets using Google Trends. *Scientific Reports*, 3:1684, 2013.
- Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, and Andrey Gulin. CatBoost: Unbiased boosting with categorical features. In *Advances in Neural Information Processing Systems 31 (NeurIPS 2018)*, pages 6638–6648, 2018.
- Dita Raditya, P. Nicholas Erlin, S. Ferarida Amanda, and Novita Hanafiah. Predicting sneaker resale prices using machine learning. *Procedia Computer Science*, 179:533–540, 2021.
- Luc Renneboog and Christophe Spaenjers. Buying beauty: On prices and returns in the art market. *Management Science*, 59(1):36–53, 2013.

Gideon Schwarz. Estimating the dimension of a model. *The Annals of Statistics*, 6(2):461–464, 1978.

Timm O. Sprenger, Andranik Tumasjan, Philipp G. Sandner, and Isabell M. Welp. Tweets and trades: The information content of stock microblogs. *European Financial Management*, 20(5):926–957, 2014.

Paul C. Tetlock. Giving content to investor sentiment: The role of media in the stock market. *Journal of Finance*, 62(3):1139–1168, 2007.

Paul C. Tetlock, Maytal Saar-Tsechansky, and Sofus Macskassy. More than words: Quantifying language to measure firms’ fundamentals. *Journal of Finance*, 63(3):1437–1467, 2008.

Nikolaos Vlastakis and Raphael N. Markellos. Information demand and stock market volatility. *Journal of Banking & Finance*, 36(6):1808–1821, 2012.

Nadia Vozlyublennaya. Investor attention, index performance, and return predictability. *Journal of Banking & Finance*, 41:17–35, 2014.

Ivo Welch and Amit Goyal. A comprehensive look at the empirical performance of equity premium prediction. *Review of Financial Studies*, 21(4):1455–1508, 2008.

Kenneth D. West. Asymptotic inference about predictive ability. *Econometrica*, 64(5):1067–1084, 1996.

A Benjamini–Hochberg 보정 전후 비교

표 18는 15회 Granger 검정 결과에 대해 Benjamini–Hochberg FDR 보정($q = 0.05$)을 적용한 결과를 raw p -값과 함께 제시한다.

BH 보정 적용 시 sneakers CH1($p = 0.041$)과 CH4($p = 0.035$)가 유의에서 탈락하여 SIGNIFICANT는 2개(sneakers CH3, cards CH1)만 남는다. 이 경우 RQ2의 Jaccard 유사도는 모든 자산쌍이 0.000이 되며, sneakers의 Model B 채널 구성은 CH3 단독으로 축소된다. 본문의 주 분석은 raw p -값을 사용하나, 본 견고성 검토 결과는 결론을 잠정적 발견으로 제시하는 본문 기조와 정합된다.

B 아이템 교체 이력

최초 후보 아이템 선정 이후 데이터 수집 과정에서 다음의 교체가 이루어졌다.

C 채널 간 상관행렬

표 20는 자산별 5개 채널 점수(CH1–CH5) 간 Pearson 상관계수를 제시한다. 단독(bivariate) Granger 검정은 채널을 한 번에 하나씩만 투입하므로 다중공선성이 주 분석에 직접 영향을 미치지 않으나, 본 연구의 §4.6에서 5채널을 동시에 투입한 6변수 VAR을 적합한 이유는 바로 본 표가 보여주는 일부 채널쌍의 상관(특히 cards CH2–CH3 $r = 0.763$) 때문이다. VAR 결과에서 단독으로는 유의 또는 경계였던 sneakers CH1 · CH4와 cards CH2가 다른 4개 채널을 통제된 뒤 NS/MARG로 약화된 사실은, 단독 검정의 일부 유의 판정이 다른 채널 효과의 흡수에 부분적으로 의존했을 가능성을 본 표의 상관 구조와 함께 시사한다.

D 재현성·데이터·코드 공개

본 연구의 재현성(reproducibility)을 위해, 데이터 수집·전처리·분석에 사용된 모든 스크립트와 정제된 패널 데이터, 그리고 통계 검정·머신러닝 결과 산출물을 공개 저장소를 통해 제공한다. 본 절은 원자료 공개의 법적 제약과 재현 가능한 분석 파이프라인의 보존 사이의 균형을 고려하여 다음 원칙에 따라 구성된다.

표 18: 15회 Granger 검정에 대한 Benjamini–Hochberg(BH) FDR 보정 ($q = 0.05$) 전후 비교. “BH 임계” 열은 raw p -값을 오름차순으로 정렬한 순위 k 에 대해 $k/15 \times 0.05$ 로 계산되며, raw p -값이 BH 임계보다 작은 경우에만 BH 보정 후에도 SIGNIFICANT로 유지된다. 본문 주 분석은 raw p -값을 1차 판정 지표로 사용하지만, 다중 검정으로 인한 거짓 양성 가능성을 독립적으로 확인하기 위해 본 표에서 BH 보정 결과를 함께 제시한다. BH 보정 적용 시 sneakers CH1($p = 0.041$)과 CH4($p = 0.035$)가 유의에서 탈락하여 SIGNIFICANT는 2개(sneakers CH3, cards CH1)만 남으며, 이 경우 RQ2의 Jaccard 유사도는 모든 자산쌍에서 0이 되고 Model B의 sneakers 채널 구성은 CH3 단독으로 축소된다. 표의 마지막 행은 표에 제시되지 않은 10개 조합 모두 raw $p > 0.18$ 로 BH 보정 전후 동일하게 NOT_SIG임을 표시한다.

자산	채널	F	raw p	BH 임계	raw 판정	BH 판정
sneakers	CH3 뉴스 감성	13.38	0.0007	0.0033	SIGNIFICANT	SIGNIFICANT
cards	CH1 Google Trends	8.42	0.006	0.0067	SIGNIFICANT	SIGNIFICANT
sneakers	CH4 YouTube 조회수	4.73	0.035	0.010	SIGNIFICANT	NOT_SIG
sneakers	CH1 Google Trends	3.47	0.041	0.013	SIGNIFICANT	NOT_SIG
lego	CH1 Google Trends	3.92	0.054	0.017	MARGINAL	NOT_SIG
(나머지 10개 조합: $p > 0.18$, 전후 동일하게 NOT_SIG)						

주. BH 임계 = $k/15 \times 0.05$ (k : 오름차순 순위). BH 적용 시 SIGNIFICANT가 4개에서 2개로 감소.

표 19: 최초 후보 아이템 선정 이후의 자료원·아이템 교체 이력과 그 사유. 본 표는 데이터 수집 과정의 투명성을 위해 모든 변경 이력을 정리한다. 변경은 네 범주로 분류된다. (i) **출시일 결측**: 후보 아이템의 출시일이 분석 시작 시점(2022-01)보다 늦어 초기 월 가격 자료가 부재한 경우 (예: Jordan 1 Chicago L&F는 2022-11 출시로 2022-01~07 결측). (ii) **URL 오류**: 자료원에서 후보 아이템의 URL이 다른 카드로 리다이렉트되는 경우(Charizard Evolving Skies #74). (iii) **Google Trends 검색량 부족**: CH1 신호 확보가 불가능한 경우(레고 1차 교체 5건). (iv) **자료원 변경**: 자료원 자체가 분석 기간을 충분히 포괄하지 못해 다른 자료원으로 전환한 경우(레고는 PriceCharting이 2023-11 이후만 보유하여 BrickRanker로 전환). 본 표는 향후 재현 연구에서 동일 아이템·자료원 조합 선택 시의 시행착오를 줄이는 참고 자료로 활용 가능하다.

자산군	교체 전	교체 후	사유
sneakers	Jordan 1 Chicago L&F	Jordan 1 Bordeaux	Chicago L&F 출시 2022-11, 2022-01~07 결측
cards	Charizard Evolving Skies #74	Charizard Shining Fates SV107	URL이 Champion's Path 카드로 리다이렉트
lego (1차)	AT-AT 75313	Millennium Falcon 75192	Google Trends 검색량 부족(CH1 신호 확보 불가)
lego (1차)	Taj Mahal 10256	Eiffel Tower 10307	동일 사유
lego (1차)	Home Alone 10292	Back to the Future 10300	동일 사유
lego (1차)	Stranger Things 75810	Hogwarts Castle 71043	동일 사유
lego (1차)	Haunted House 10273	Ferrari Daytona SP3 42143	동일 사유
lego (2차)	Eiffel Tower 10307	Titanic 10294	출시일 결측 10개월
lego (2차)	Back to the Future 10300	Razor Crest 75331	출시일 결측 3개월
lego (2차)	Ferrari Daytona SP3 42143	Porsche 911 42096	출시일 결측 5개월
lego (3차)	Razor Crest 75331	Bugatti Chiron 42083	GT 0값 과다(30/48개월), Porsche로 교체 후 잔여 후보 중 최선
lego (소스)	PriceCharting	BrickRanker	PriceCharting 레고는 2023-11 이후 데이터만 존재

표 20: 자산별 5개 채널 점수(CH1-CH5) 간 Pearson 상관계수 (상삼각 표시). 본 연구의 Granger 검정은 단독(bivariate) 설계로 채널을 한 번에 하나씩만 투입하므로, 채널 간 다중공선성은 주 분석에 직접 영향을 미치지 않는다. 그러나 향후 다중 채널 동시 투입 회귀 분석을 시도하는 후속 연구를 위해 사전 점검 자료로 본 행렬을 제시한다. 굵음 표기는 $|r| \geq 0.7$ (높은 상관)을 의미하며, cards의 CH2(뉴스 보도량)-CH3(뉴스 감성) 쌍이 $r = 0.763$ 으로 다중공선성 우려 수준에 해당한다. 이는 카드 시장의 경우 보도량과 감성이 동조하여 변동함을 시사하며, 다중 채널 회귀 시 분산 팽창 계수(VIF) 점검이 권고된다. 그 외 자산에서는 모든 채널 쌍이 $|r| < 0.6$ 이내로 다중공선성 우려가 낮다.

자산		CH1	CH2	CH3	CH4	CH5
sneakers	CH1	1.000	0.120	0.128	-0.172	0.201
	CH2		1.000	0.386	-0.155	0.072
	CH3			1.000	-0.073	0.112
	CH4				1.000	-0.028
	CH5					1.000
cards	CH1	1.000	0.225	0.172	0.394	-0.339
	CH2		1.000	0.763	0.105	-0.020
	CH3			1.000	0.014	0.070
	CH4				1.000	-0.379
	CH5					1.000
lego	CH1	1.000	0.106	0.085	-0.060	-0.070
	CH2		1.000	0.596	0.097	0.021
	CH3			1.000	0.073	0.022
	CH4				1.000	0.129
	CH5					1.000

주. 굵음: $|r| \geq 0.7$ (높은 상관). cards의 CH2-CH3(뉴스 보도량-뉴스 감성) 쌍이 $r = 0.763$ 으로 다중공선성 우려 수준. 다중 채널 동시 투입 시 VIF 확인 권고.

공개 저장소. GitHub 공개 저장소를 통해 분석 코드 일체와 처리된 분석용 데이터를 제공한다.¹¹

디렉토리 구조. 저장소는 다음의 5개 최상위 디렉토리로 구성된다.

- `scripts/` — 데이터 수집 (`collect_*.py`), 전처리 (`build_panel.py`, `score_channels.py`), 통계 검증 (`run_adf.py`, `run_granger.py`), 머신러닝 (`run_xgboost.py`, `run_shap.py`, `run_dm.py`), 추가 검증 (`ablation.py`, `tune_xgboost.py`, `run_model_c.py`, `run_model_comparison.py`) 스크립트.
- `data/raw/` — 자료원별 원본 자료 (StockX 거래가, PriceCharting PSA 10 가격, BrickRanker 신품 봉인 가격, GDELT timelinevolnorm·timelinetone, pytrends

검색량, YouTube 영상·댓글).

- `data/processed/` — 분석에 직접 투입되는 패널 (`panel_monthly.csv`, `panel_monthly_scaled.csv`, `asset_series.csv`, `channel_scores.csv`).
 - `results/` — 본문·부록의 표·그림 산출에 사용된 결과 파일 (`stationarity.csv`, `granger_results.csv`, `channel_importance.csv`, `xgboost_auc.csv`, `model_comparison_auc.csv`, `model_c_results.csv`, `figures/`).
 - `paper/` — 본 L^AT_EX 원고와 `references.bib`.
- 환경 및 의존성.** Python 3.11 기반이며, 핵심 의존성은 `pandas`, `statsmodels`(ADF·Granger·DM), `xgboost`, `shap`, `scikit-learn`(`TimeSeriesSplit`, `StandardScaler`), `transformers`(`FinBERT`), `pytrends`, `playwright`(StockX 우회), `undetected-`

¹¹출판 시 저장소 URL을 확정·공개하며, 익명 리뷰 단계에서는 익명 미러를 통해 접근 가능하도록 한다(예: `anonymous.4open.science`). 본 원고 작성 시점의 임시 저장 위치는 저자 제공.

chromedriver 이다. 완전한 버전 명세와 requirements.txt는 저장소 루트에 포함된다.

실행 절차. 저장소 README.md는 (i) 환경 구축 (pip install -r requirements.txt), (ii) 데이터 재수집 (API 키 설정 후 scripts/collect_*.py 실행) 또는 제공된 처리 데이터로 분석만 재현, (iii) 본 원고 표·그림 재산출 명령을 순차적으로 안내한다. 본 원고에 제시된 모든 수치는 단일 명령 (python scripts/run_all.py) 으로 약 30분 이내에 재산출 가능하다.

재수집의 한계. StockX와 BrickRanker는 비 공식 웹 스크래핑을 통해 수집되었으므로, 저작권과 약관 준수를 위해 원자료 raw HTML은 저장소에 포함하지 않는다. 대신 가공된 시계열 (data/raw/prices/ {item_id}.csv) 만을 공개하며, 동일 스크래핑 스크립트의 재실행은 대상 사이트의 정책 변경 시 결과가 달라질 수 있음을 명시한다. GDELT·pytrends·YouTube Data API는 공식 API 사용이므로 재실행 시 거의 동일한 결과 재현이 보장된다.